

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN – TIN



DEEP LEARNING CHO KHOA HỌC DỮ LIỆU

ĐỀ TÀI

Hồi sinh ký ức: Phục hồi ảnh cũ với dữ liệu hiếm bằng
hệ thống học sâu mô-đun

*Reviving Memories: Old Photo Restoration with Scarce Data using a Modular Deep Learning
System*

NHÓM 17

Giảng viên hướng dẫn: ThS. Hà Minh Tuấn

Sinh viên thực hiện: MSSV

Trần Quang Sáng 23280081

Nguyễn Thanh Triết 23280095

Trần Chí Vĩ 23280098

Thành phố Hồ Chí Minh, ngày 11 tháng 12 năm 2025

LỜI CẢM ƠN

Nhóm thực hiện xin gửi lời cảm ơn đến giảng viên phụ trách học phần Deep Learning vì đã định hướng cách tiếp cận bài toán theo tinh thần nghiên cứu, yêu cầu nhóm không chỉ dừng lại ở việc chạy mô hình mà còn phải phân tích vấn đề, thiết kế thí nghiệm, đánh giá kết quả và trình bày hạn chế một cách trung thực[cite: 1]. Yêu cầu viết báo cáo theo phong cách luận văn giúp nhóm hình thành thói quen tổ chức nội dung có hệ thống, từ bối cảnh, cơ sở lý thuyết, phương pháp, thực nghiệm đến thảo luận và hướng phát triển[cite: 1].

Nhóm cũng xin cảm ơn các thành viên đã tham gia vào quá trình xây dựng dữ liệu, huấn luyện mô hình, thử nghiệm pipeline, kiểm tra kết quả, chuẩn hóa tài liệu và rà soát các khẳng định kỹ thuật[cite: 1]. Báo cáo này được biên soạn như một luận văn thu nhỏ: trọng tâm không chỉ là kết quả cuối cùng, mà còn là quá trình nhận diện thất bại, phân tích nguyên nhân, điều chỉnh phương pháp và kiểm soát phạm vi kết luận[cite: 1].

TÓM TẮT

Phục hồi ảnh cũ là bài toán thị giác máy tính quan trọng, nhằm bảo tồn ký ức gia đình và tư liệu lịch sử. Ảnh cũ thường chịu nhiều dạng suy thoái đồng thời: nhiễu, mờ, phai màu, vết nứt, vết xước và vùng mất dữ liệu. Do các suy thoái có bản chất khác nhau, một mô hình duy nhất khó xử lý toàn diện.

Đề tài xây dựng hệ thống phục hồi ảnh cũ theo kiến trúc mô-đun gồm bốn module chính: (1) phân đoạn vết nứt/vết xước bằng Attention U-Net, (2) inpainting vùng hỏng bằng LaMa, (3) phục hồi màu sắc dựa trên U-Net trong không gian Lab kết hợp kiểm soát suy luận và ma trận hiệu chỉnh màu, (4) tùy chọn phục hồi khuôn mặt bằng CodeFormer. Cách tiếp cận này cho phép kiểm soát cục bộ, giảm tác động lên vùng ảnh còn tốt và dễ dàng phân tích lỗi.

Quá trình phát triển bắt đầu từ baseline U-Net end-to-end. Mô hình này đạt kết quả khả quan trên dữ liệu tổng hợp nhưng không ổn định trên ảnh thật do khoảng cách miền dữ liệu (domain gap) và hiện tượng làm mờ. Do đó, đề tài chuyển sang chiến lược data-centric, cải thiện dữ liệu huấn luyện phân đoạn bằng các mẫu vết nứt thực tế kết hợp mô hình hóa bề mặt và chiếu sáng. Sau loạt thực nghiệm R006–R013, segmenter R013 được chọn làm checkpoint ổn định. Inpainting sử dụng LaMa pretrained, không fine-tune. Module phục hồi màu được huấn luyện trên dữ liệu paired synthetic với profile suy giảm giữ lại chroma, sử dụng loss tổng hợp (RGB, Lab, SSIM, histogram, identity) và các cơ chế kiểm soát inference (blending, chroma gate, CCM). CodeFormer là module tùy chọn, có cảnh báo rủi ro hallucination.

Hệ thống được đóng gói với CLI, giao diện Gradio, readiness checker và quản lý artifact bằng manifest. Kết quả thực nghiệm cho thấy R014 (ResNet-34 encoder) cải thiện segmentation so với R013, nhưng chất lượng ảnh phục hồi cuối phụ thuộc nhiều vào hình thái mask. Module phục hồi màu giúp giảm ám vàng và cải thiện độ bão hòa một cách an toàn. Các hạn chế chính bao gồm dữ liệu ảnh thật có nhãn nhỏ, domain gap chưa được khắc phục hoàn toàn, và thiếu benchmark phục hồi quy mô lớn. Hướng phát triển ưu tiên là mở rộng dữ liệu, cải thiện mask refinement, và đánh giá toàn diện hơn.

Phục hồi ảnh cũ là một bài toán thị giác máy tính có ý nghĩa thực tiễn cao, gắn với nhu cầu bảo tồn ký ức cá nhân, tư liệu gia đình và tài liệu lịch sử. Khác với các bài toán khôi phục ảnh thông thường, ảnh cũ thường chứa nhiều dạng suy thoái đồng thời, bao gồm nhiễu hạt, mờ, phai màu, ố vàng, vết nứt, vết xước và vùng mất dữ liệu cục bộ[cite: 1]. Các suy thoái này có bản chất khác nhau: một số tác động rộng trên toàn ảnh, trong khi vết nứt và vết xước là các khuyết tật có cấu trúc hình học rõ ràng, cần được định vị trước khi phục hồi[cite: 1].

Đề tài nghiên cứu và xây dựng một hệ thống phục hồi ảnh cũ theo kiến trúc mô-đun[cite: 1]. Thay vì dùng một mạng end-to-end duy nhất để ánh xạ ảnh hỏng sang ảnh sạch, hệ thống tách bài toán thành các bước: phân đoạn vết nứt/vết xước, tinh chỉnh mặt nạ bằng kết hợp giữa mô hình học sâu và xử lý ảnh truyền thống, sau đó dùng inpainting để lấp vùng hư hỏng[cite: 1]. Cách tiếp cận này giúp kiểm soát vùng cần sửa, giảm nguy cơ làm thay đổi toàn ảnh và cho phép đánh giá từng module độc lập[cite: 1].

Quá trình phát triển bắt đầu từ một baseline U-Net end-to-end[cite: 1]. Kết quả trên dữ liệu tổng hợp cho thấy mô hình có thể đạt một số chỉ số định lượng nhất định, nhưng không ổn định trên ảnh thật do domain gap và hiện tượng làm mờ chi tiết[cite: 1]. Từ đó, đề tài chuyển sang hướng data-centric: cải thiện dữ liệu huấn luyện bằng các mẫu vết nứt có alpha mask, heightmap, normal map, mô hình chiếu sáng và alpha blending để tạo dữ liệu paired phục vụ segmentation[cite: 1].

Ở module phân đoạn, đề tài xây dựng chuỗi thực nghiệm R006 đến R013[cite: 1]. Các kết quả cho thấy synthetic pretraining có ích nhưng chưa đủ đại diện cho ảnh thật; real-domain fine-tuning và thiết kế target mask có ảnh hưởng lớn đến chất lượng mask[cite: 1]. R013 được chọn làm checkpoint vận hành hiện tại cho Module 1 vì được huấn luyện trên tập 118 cặp ảnh-mặt nạ hợp lệ, có kết quả ổn định giữa historical artifact và reproduction, đồng thời cải thiện so với R011 trong so sánh công bằng trên cùng tập test cố định[cite: 1].

Module inpainting tích hợp pretrained LaMa thông qua cơ chế subprocess wrapper[cite: 1]. Đề tài không khẳng định đã fine-tune LaMa, không dùng LPIPS/FID như kết quả đã đo nếu chưa có benchmark đầy đủ, và không cam kết bảo toàn danh tính khuôn mặt khi dùng module phục hồi khuôn mặt tùy chọn[cite: 1]. Báo cáo trình bày rõ phạm vi triển khai, kết quả hiện có, phân tích lỗi theo module, hạn chế và hướng phát triển nhằm bảo đảm tính trung thực học thuật[cite: 1].

ABSTRACT

Old photo restoration is an important computer vision problem for preserving family memories and historical documents. Old photos often suffer from multiple simultaneous degradations: noise, blur, color fading, cracks, scratches and missing regions. Because these degradations are heterogeneous, a single model cannot handle all of them effectively.

This project develops a modular deep learning system for old photo restoration, consisting of four main modules: (1) crack/scratch segmentation using an Attention U-Net, (2) LaMa inpainting, (3) color restoration using a Lab-space U-Net with inference control and a color correction matrix, and (4) optional CodeFormer face restoration. The modular design enables local control, reduces impact on intact regions and simplifies error analysis.

Development started from an end-to-end U-Net baseline. Although it achieved reasonable results on synthetic data, it was unstable on real old photos due to domain gap and blurring artifacts. Hence, the project adopted a data-centric strategy, improving segmentation training data using real crack samples with surface and illumination modeling. After experiments R006–R013, segmenter R013 was selected as a stable checkpoint. Inpainting uses a pretrained LaMa backend without fine-tuning. The color restoration module is trained on paired synthetic data with a degradation profile that retains chroma, using a combined loss (RGB, Lab, SSIM, histogram, identity) and inference controls (blending, chroma gate, CCM). CodeFormer is optional with hallucination warnings.

The system is packaged with a CLI, Gradio UI, readiness checker and artifact management via manifest. Experimental results show that R014 (ResNet-34 encoder) improves segmentation over R013, but final restoration quality strongly depends on mask morphology. The color restoration module safely reduces yellow casts and improves saturation. Key limitations include the small size of real annotated data, remaining domain gaps, and the lack of a large-scale restoration benchmark. Future priorities are data expansion, improved mask refinement, and more comprehensive evaluation.

Old photo restoration is a practical computer vision problem related to the preservation of personal memories, family archives and historical documents[cite: 1]. Unlike standard image restoration tasks, old photos often contain multiple degradation types, including noise, blur, color fading, stains, cracks, scratches and local missing regions[cite: 1]. These degradations are heterogeneous: some are global and unstructured, whereas cracks and scratches are structured defects that should be localized before content completion is performed[cite: 1].

This project studies and develops a modular deep learning system for old photo restoration[cite: 1]. Instead of relying on a single end-to-end image-to-image network, the proposed system decomposes the task into crack segmentation, hybrid mask refinement and image inpainting[cite: 1]. This design enables local control, intermediate inspection and module-level error analysis[cite: 1].

The development process started from an end-to-end U-Net baseline[cite: 1]. Although the baseline achieved measurable values on synthetic data, it did not generalize reliably to real old photos due to domain gap and averaging artifacts[cite: 1]. The project therefore shifted toward a data-centric

strategy, where crack synthesis is improved using crack samples, alpha masks, heightmaps, normal maps, illumination modeling and alpha blending[cite: 1].

The crack segmentation module was trained through a sequence of experimental runs from R006 to R013[cite: 1]. The final operational segmenter, R013, was trained on 118 valid image-mask pairs and evaluated with a fixed split[cite: 1]. It showed stable historical and reproduction results and improved over R011 under fair comparison on the same fixed test set[cite: 1]. The inpainting stage integrates pretrained LaMa through a subprocess wrapper[cite: 1]. The report carefully separates implemented results from future work, including LaMa fine-tuning, perceptual metrics and identity-aware face restoration evaluation[cite: 1].

DANH MỤC TỪ VIẾT TẮT

Bảng 1: Danh mục từ viết tắt sử dụng trong báo cáo

Từ viết tắt	Tên đầy đủ	Ý nghĩa trong báo cáo
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập dùng để trích xuất đặc trưng ảnh.
U-Net	U-shaped Network	Kiến trúc encoder-decoder có skip connection, dùng cho segmentation và restoration.
BCE	Binary Cross Entropy	Hàm mất mát phân loại nhị phân ở mức pixel.
IoU	Intersection over Union	Chỉ số đo độ trùng giữa mask dự đoán và ground-truth mask.
F1/Dice	Dice similarity coefficient	Chỉ số đo độ tương đồng giữa hai vùng nhị phân.
PSNR	Peak Signal-to-Noise Ratio	Chỉ số toàn tham chiếu đánh giá sai khác pixel.
SSIM	Structural Similarity Index Measure	Chỉ số toàn tham chiếu đánh giá tương đồng cấu trúc ảnh.
LPIPS	Learned Perceptual Image Patch Similarity	Khoảng cách cảm nhận dựa trên đặc trưng mạng học sâu.
LaMa	Large Mask Inpainting	Mô hình inpainting sử dụng Fast Fourier Convolution.
FFC	Fast Fourier Convolution	Tích chập trong miền tần số, mở rộng receptive field toàn ảnh.
Lab	CIELAB color space	Không gian màu chuẩn, tách luminance (L) khỏi chroma (a,b), dùng trong phục hồi màu.
CCM	Color Correction Matrix	Ma trận hiệu chỉnh màu toàn cục, dạng đường chéo dựa trên gray-world.
EMD	Earth Mover's Distance	Khoảng cách giữa hai histogram, dùng trong loss để căn chỉnh phân phối chroma.

Từ viết tắt	Tên đầy đủ	Ý nghĩa trong báo cáo
CLAHE	Contrast Limited Adaptive Histogram Equalization	Cân bằng histogram thích ứng có giới hạn tương phản, chỉ áp dụng trên kênh L.
NLMeans	Non-local Means Denoising	Phương pháp khử nhiễu bảo toàn cấu trúc, dùng trong preprocessing.
AMP	Automatic Mixed Precision	Kỹ thuật huấn luyện với độ chính xác hỗn hợp (float16/float32).
GroupNorm	Group Norm.	Chuẩn hóa theo nhóm kênh, ổn định với batch size nhỏ.
AdamW	Adam with Weight Decay	Biến thể của Adam tách weight decay khỏi gradient update.
VQVAE	Vector Quantized Variational AutoEncoder	Mã hóa tự biến thiên có lượng tử hóa, dùng trong CodeFormer.
Transformer	Transformer	Kiến trúc attention đa đầu, dùng để mô hình hóa quan hệ giữa các token.
RetinaFace	RetinaFace	Bộ phát hiện khuôn mặt mạnh mẽ, dùng để kích hoạt module CodeFormer.
CLI	Command Line Interface	Giao diện dòng lệnh để chạy pipeline.
CV	Computer Vision	Nhóm kỹ thuật xử lý ảnh truyền thống (Canny, morphology, thresholding).
DL	Deep Learning	Nhóm phương pháp học sâu dùng mạng nơ-ron.
R006–R014	Experiment runs	Chuỗi cấu hình huấn luyện segmenter, thể hiện quá trình nghiên cứu lặp.

Mục lục

LỜI CẢM ƠN	i
TÓM TẮT	ii
ABSTRACT	iv
DANH MỤC TỪ VIẾT TẮT	vi
DANH MỤC HÌNH VẼ	xii
DANH MỤC BẢNG	xiii
1 Giới thiệu	1
1.1 Bối cảnh bài toán phục hồi ảnh cũ	1
1.2 Động cơ chọn đề tài	1
1.3 Vấn đề nghiên cứu	2
1.4 Mục tiêu đề tài	3
1.5 Phạm vi thực hiện	5
1.6 Đóng góp chính của đề tài	5
1.7 Cấu trúc báo cáo	7
2 Cơ sở lý thuyết và công trình liên quan	8
2.1 Tổng quan về bài toán Phục hồi ảnh cũ và phân loại suy thoái	8
2.1.1 Bản chất toán học của bài toán nghịch đảo (Inverse Problem)	8
2.1.2 Phân loại suy thoái trong ảnh cũ	8
2.2 Cơ sở lý thuyết về Phân đoạn vùng hư hỏng (Segmentation)	9
2.2.1 Mạng nơ-ron tích chập (CNN) và Giới hạn vùng cảm thụ (Receptive Field)	9
2.2.2 Cơ chế Attention Gate và Deep Supervision trong bộ giải mã	9
2.2.3 Kiểm soát tính toàn vẹn dữ liệu (Data Integrity) trong huấn luyện phân đoạn	10
2.2.4 Động lực học của các Hàm mất mát cân bằng lớp	10
2.3 Cơ sở lý thuyết về Lấp vùng ảnh hỏng và Phục hồi (Restoration)	10
2.3.1 Inpainting với LaMa và Fast Fourier Convolution	11
2.3.2 Phục hồi màu sắc trong không gian Lab	11
2.3.3 Phục hồi khuôn mặt qua prior không gian tiềm ẩn	12
2.4 Các công trình nghiên cứu liên quan	13
3 Hệ thống phục hồi ảnh cũ đề xuất	14
3.1 Kiến trúc tổng quan của pipeline đề xuất	15
3.1.1 Mô hình hóa bề mặt vật lý không gian ba chiều	17
3.1.2 Giả lập mô hình chiếu sáng Phong và Alpha Blending	17
3.2 Quy trình tổng hợp dữ liệu vết nứt nâng cao (Data-centric Pipeline)	17
3.2.1 Khai thác dữ liệu nền và xây dựng Crack Bank	18
3.2.2 Mô hình hóa bề mặt vật lý không gian ba chiều (Heightmap & Normal Map)	18
3.2.3 Giả lập mô hình chiếu sáng Phong và Alpha Blending	19
3.3 Module 1: Phân đoạn vết nứt dựa trên Attention U-Net	19
3.3.1 Kiến trúc cơ sở: Custom lightweight Attention U-Net (R013)	20
3.3.2 Thử nghiệm bóc tách: Nâng cấp bộ trích xuất đặc trưng với ResNet-34 (R014)	20
3.4 Nhánh tinh chỉnh mặt nạ lai (Hybrid Mask Refinement)	21
3.5 Module 2: Inpainting sử dụng Pretrained LaMa Backend thông qua Subprocess Wrapper	21
3.6 Module 3: Phục hồi màu ảnh sau LaMa (Color Restoration)	22
3.6.1 Chiến lược dữ liệu và tiền xử lý	23
3.6.2 Kiến trúc ColorRestorationUNet và dự đoán residual trong không gian Lab	23

3.6.3	Hàm mất mát tổng hợp	24
3.6.4	Inference trên ảnh full-resolution (Tiled inference)	24
3.6.5	Kiểm soát suy luận (Inference Control)	24
3.6.6	Color Correction Matrix (CCM) toàn cục	24
3.7	Module 4: Phục hồi khuôn mặt tùy chọn với CodeFormer	25
3.7.1	Luồng hoạt động có điều khiển bằng cổng (Conditional Gate)	26
3.7.2	Rủi ro hallucination và giới hạn diễn giải	26
3.7.3	Cấu hình vận hành	27
4	Thiết lập thực nghiệm và triển khai hệ thống	28
4.1	Mở đầu	28
4.2	Mục tiêu của thiết lập thực nghiệm	28
4.3	Môi trường thực nghiệm và hệ quả thiết kế	29
4.4	Dữ liệu sử dụng và vai trò của từng miền dữ liệu	30
4.4.1	Tổng quan các nhóm dữ liệu	30
4.4.2	Dữ liệu cho segmentation: <code>r013_finetune_set</code> và <code>split</code> cố định	30
4.4.3	Dữ liệu cho module phục hồi màu (Color Restoration)	31
4.5	Tiền xử lý và chuẩn hóa	31
4.5.1	Cho segmentation: R013 và R014	31
4.5.2	Cho module màu: OpenCV conservative preprocessing	31
4.6	Thiết lập huấn luyện	31
4.6.1	Segmenter: R013 và R014	31
4.6.2	Module phục hồi màu (ColorRestorationUNet)	32
4.7	Quản lý checkpoint, artifact và khả năng tái lập	32
4.8	Triển khai runtime: CLI, UI, readiness checker và dependency ngoài	32
4.8.1	Command-line interface (CLI)	33
4.8.2	Gradio UI	33
4.8.3	Readiness checker	33
4.8.4	Subprocess wrapper cho LaMa	33
4.9	Kiểm thử hồi quy và phạm vi diễn giải	33
4.10	Kết luận chương	34
5	KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN	35
5.1	Mở đầu	35
5.2	Mục tiêu và phạm vi đọc kết quả	35
5.2.1	Câu hỏi cho Module 1	35
5.2.2	Câu hỏi cho Module 3	36
5.3	Module 1 – Phân đoạn và phục hồi vết nứt	36
5.3.1	Kết quả baseline end-to-end	36
5.3.2	Synthetic pretraining và bằng chứng domain gap	37
5.3.3	Real-domain fine-tuning R010–R013	39
5.3.4	So sánh segmentation cuối: R013 (Attention U-Net) vs R014 (ResNet-34)	40
5.3.5	Restoration check: ảnh hưởng của mask morphology	42
5.3.6	Threshold/dilation sweep cho R014	43
5.4	Module 3 – Phục hồi màu sau inpainting	43
5.4.1	Kết quả định lượng ước tính	44
5.4.2	Khả năng hiệu chỉnh theo vùng (spatially-varying)	44
5.4.3	Hạn chế của kết quả ước tính	44
5.5	Đánh giá định tính tổng hợp và smoke test	45
5.5.1	Đánh giá định tính	45
5.5.2	Demo3 regression test	46
5.6	Phân tích lỗi theo module	47

5.7	Thảo luận tổng hợp	47
5.7.1	Module 1	47
5.7.2	Module 3	48
5.7.3	Bài học phương pháp luận	48
5.8	Kết luận chương	48
6	HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN	49
6.1	Mở đầu	49
6.2	Tổng quan các nhóm hạn chế của hệ thống	49
6.3	Hạn chế về dữ liệu	50
6.3.1	Quy mô real annotated data nhỏ	50
6.3.2	Domain gap giữa synthetic và real	51
6.3.3	masks_fixed không phải repair-wide dataset	51
6.4	Hạn chế về mô hình phân đoạn	51
6.4.1	R013: encoder nhẹ, năng lực biểu diễn hạn chế	52
6.4.2	R014: cải thiện segmentation nhưng chưa hoàn hảo	52
6.4.3	Hướng phát triển cho segmenter	52
6.5	Hạn chế về mask refinement và hybrid mask	52
6.5.1	Trade-off giữa coverage và chính xác	52
6.5.2	Hybrid mask và policy tĩnh	52
6.5.3	Hướng phát triển	53
6.6	Hạn chế về LaMa inpainting backend	53
6.6.1	Pretrained, chưa domain-adapt	53
6.6.2	Phụ thuộc mạnh vào mask	53
6.6.3	Hướng phát triển	54
6.7	Hạn chế về CodeFormer và phục hồi khuôn mặt	54
6.8	Hạn chế của module phục hồi màu (Color Restoration)	54
6.8.1	Domain gap giữa synthetic training và ảnh thật	54
6.8.2	Không phải mô hình colorization	55
6.8.3	Inference control là heuristic, không được tối ưu end-to-end	55
6.8.4	Chưa có benchmark chính thức trên tập test độc lập	55
6.8.5	Chưa đánh giá LPIPS và các metric cảm nhận khác	55
6.8.6	Hạn chế về mặt kỹ thuật trong implementation	55
6.8.7	Hướng phát triển cho module phục hồi màu	56
6.9	Hạn chế về đánh giá thực nghiệm	57
6.9.1	Phạm vi còn hẹp	57
6.9.2	Demo3 không phải benchmark	57
6.9.3	Hướng phát triển đánh giá	57
6.10	Hạn chế về triển khai và phần mềm	58
6.11	Hạn chế về phạm vi bài toán	58
6.12	Hướng phát triển ưu tiên	59
6.13	Kết luận chương	60
7	TỔNG KẾT VÀ KẾT LUẬN	61
7.1	Mở đầu	61
7.2	Tổng kết bài toán và hướng tiếp cận	61
7.3	Tổng kết quá trình phát triển phương pháp	61
7.3.1	Giai đoạn end-to-end và chuyển hướng	62
7.3.2	Phát triển segmentation và bài học mask morphology	62
7.3.3	Phát triển module phục hồi màu	62
7.4	Tổng kết kết quả thực nghiệm chính	62

7.5	Mức độ hoàn thành mục tiêu đề tài	63
7.6	Đóng góp và bài học rút ra	64
7.6.1	Đóng góp chính	65
7.6.2	Bài học phương pháp luận	65
7.7	Giới hạn còn lại và kết luận cuối cùng	65
A	Khung phân công công việc nhóm	68

Danh sách hình vẽ

3.1	Kiến trúc pipeline phục hồi ảnh cũ đã tối ưu diện tích.	15
3.2	Sơ đồ Degradation pipeline tạo dữ liệu training từ ảnh sạch và Crack Bank	18
3.3	Kiến trúc Module 1 với hai option R013 (custom lightweight Attention U-Net) và R014 (ResNet-34 + U-Net + AG). Hình minh họa cấu trúc chung của U-Net với Attention Gate và Deep Supervision.	19
3.4	Kiến trúc luồng xử lý và đánh giá Loss theo thiết kế Trục Kép (Twin-Bus) của Module 2.	21
3.5	Luồng xử lý của Module 3 — Phục hồi màu sau LaMa.	23
3.6	Luồng xử lý của Module 4: phát hiện khuôn mặt bằng RetinaFace, nếu có thì kích hoạt CodeFormer (VQVAE codebook + Transformer) để phục hồi chi tiết vùng mặt, sau đó blend lại ảnh gốc. Module này là tùy chọn, có cảnh báo rủi ro hallucination.	25
4.1	Luồng thiết lập thực nghiệm: từ dữ liệu, split cố định, huấn luyện R013/R014, đánh giá segmentation, sau đó kiểm tra downstream (mask refinement, inpainting, phục hồi màu) và quản lý artifact.	29
5.1	Validation IoU trên synthetic của R006–R009.	38
5.2	Best validation IoU giữa các run synthetic.	38
5.3	Domain gap: R009 đạt IoU 0.4171 trên synthetic nhưng Real Test IoU chỉ 0.0022.	39
5.4	Tiến trình real-domain fine-tuning: Real Test IoU và F1 từ R010 đến R013.	40
5.5	So sánh định tính hoặc metric giữa R013 và R014.	41
5.6	R013: Mask -> Lama	41
5.7	R014: Mask -> Lama	42
5.8	Ảnh hưởng của threshold và dilation lên mask và kết quả inpainting.	43
5.9	Chuyển màu ảnh qua các giai đoạn thử nghiệm.	44
5.10	Tiến trình pipeline từ ảnh cũ → mask → inpainting → phục hồi màu.	45
5.11	Ví dụ minh họa pipeline đầy đủ: (a) Ảnh gốc, (b) Mask overlay, (c) LaMa inpainting, (d) Phục hồi màu, (e) CodeFormer (tùy chọn).	46
5.12	Một ví dụ khác của pipeline.	46
5.13	Ví dụ thứ ba.	46

Danh sách bảng

1	Danh mục từ viết tắt sử dụng trong báo cáo	vi
1.1	Phạm vi thực hiện và cách diễn giải trong báo cáo (cập nhật có module phục hồi màu)	5
2.1	Phân tích đặc trưng toán học và hình thái của các dạng suy thoái ảnh cũ (bổ sung nhóm màu sắc)	9
3.1	Tham số vận hành của Module 4	27
4.1	Môi trường thực nghiệm và hệ quả đối với phương pháp	29
4.2	Các nhóm dữ liệu và vai trò thực nghiệm	30
4.3	Split cố định của <code>r013_finetune_set</code>	31
4.4	Vai trò thực nghiệm của R013 và R014	32
4.5	Các loại kiểm thử và phạm vi diễn giải	33
5.1	Phạm vi sử dụng các nhóm kết quả	36
5.2	Kết quả baseline end-to-end (Module 1)	37
5.3	Kết quả synthetic pretraining và domain gap	39
5.4	Chuỗi real-domain fine-tuning R010–R013	40
5.5	So sánh R013 và R014 trên cùng split	42
5.6	Restoration check 15 mẫu (R013 vs R014 no-dilation)	42
5.7	Chính sách threshold/dilation cho R014	43
5.8	Chỉ số chất lượng ước tính của mô hình phục hồi màu (Module 3)	44
5.9	Phân biệt đánh giá định tính và kiểm thử hồi quy	47
5.10	Failure modes theo từng module (Module 1 và Module 3)	47
6.1	Tổng hợp các nhóm hạn chế chính của hệ thống (bao gồm color restoration)	50
6.2	Hạn chế dữ liệu và hướng khắc phục	51
6.3	Trade-off trong mask refinement và hướng phát triển	53
6.4	Hạn chế cụ thể của module phục hồi màu và hướng khắc phục	56
6.5	Giới hạn của các nhóm đánh giá hiện tại và hướng phát triển	58
6.6	Lộ trình phát triển ưu tiên sau đề án (tích hợp cả color restoration)	59
7.1	Các kết quả thực nghiệm chính được tổng kết (bao gồm color restoration)	63
7.2	Đối chiếu mục tiêu đề tài và mức độ hoàn thành (có bổ sung color restoration)	64
A.1	Phân công công việc (khung)	68

Chương 1

Giới thiệu

1.1. Bối cảnh bài toán phục hồi ảnh cũ

Ảnh cũ là một dạng tư liệu thị giác có giá trị cao trong nhiều ngữ cảnh: lưu giữ ký ức gia đình, bảo tồn di sản văn hóa, số hóa tư liệu lịch sử và phục dựng hình ảnh từ các kho lưu trữ[cite: 1]. Tuy nhiên, ảnh giấy và ảnh phim thường chịu tác động lâu dài của thời gian, độ ẩm, ánh sáng, hóa chất, quá trình scan và điều kiện bảo quản[cite: 1]. Những tác động này làm xuất hiện nhiều hạt, mờ, phai màu, ố vàng, vết nứt, vết xước, vết gấp và vùng mất dữ liệu cục bộ[cite: 1]. Việc phục hồi ảnh cũ vì vậy không chỉ là bài toán làm đẹp ảnh, mà còn là bài toán tái tạo lại cấu trúc thị giác sao cho hợp lý, dễ nhìn và giữ được càng nhiều nội dung gốc càng tốt[cite: 1].

Khác với nhiều bài toán image restoration trong phòng thí nghiệm, ảnh cũ thật thường không có ảnh sạch tương ứng[cite: 1]. Khi thiếu ground truth, việc huấn luyện trực tiếp theo kiểu supervised learning và đánh giá bằng PSNR hoặc SSIM trở nên hạn chế[cite: 1]. Một ảnh cũ ngoài đời có thể đồng thời bị nhiễu, nhòe, mất tương phản, phai màu, xước và rách[cite: 1]. Các loại suy thoái này không cùng bản chất, do đó một mô hình duy nhất rất khó học được toàn bộ cơ chế phục hồi một cách ổn định[cite: 1].

Trong bối cảnh học sâu, có thể phân rã phục hồi ảnh cũ thành nhiều bài toán con: phát hiện vùng hư hỏng, lấp vùng mất dữ liệu bằng inpainting, tăng cường khuôn mặt, cân bằng màu và tăng độ phân giải[cite: 1]. Mỗi bài toán con đòi hỏi loại dữ liệu, kiến trúc mô hình và tiêu chí đánh giá khác nhau[cite: 1]. Điều này dẫn đến một hướng tiếp cận hợp lý hơn cho đề án: thiết kế pipeline mô-đun, trong đó mỗi module đảm nhiệm một chức năng rõ ràng và có thể được đánh giá riêng[cite: 1].

1.2. Động cơ chọn đề tài

Đề tài được lựa chọn vì ba lý do chính:

- **Thứ nhất**, phục hồi ảnh cũ là bài toán có tính thực tiễn cao[cite: 1]. Kết quả có thể được minh họa bằng cặp ảnh trước và sau phục hồi, giúp người xem dễ đánh giá tác động của hệ thống[cite: 1].
- **Thứ hai**, bài toán phù hợp với nội dung học phần Deep Learning vì khai thác nhiều thành phần cốt lõi như CNN, segmentation, loss function cho dữ liệu mất cân bằng, inpainting và mô hình

sinh ảnh[cite: 1].

- **Thứ ba**, đề tài cho phép kết hợp giữa hướng tiếp cận data-centric và model-centric: không chỉ thay đổi kiến trúc mô hình, mà còn phải thiết kế dữ liệu huấn luyện sao cho gần với ảnh thật hơn[cite: 1].

Một động cơ quan trọng khác là bài toán tạo điều kiện để phân tích thất bại của mô hình[cite: 1]. Trong quá trình phát triển, nhóm ban đầu xây dựng một mô hình cơ sở end-to-end bằng U-Net[cite: 1]. Mô hình này có thể đạt chỉ số trên dữ liệu tổng hợp nhưng không phục hồi tốt ảnh thật[cite: 1]. Sự khác biệt này buộc nhóm phải phân tích domain gap, chất lượng dữ liệu tổng hợp và giới hạn của pixel loss[cite: 1]. Nhờ vậy, đề tài không dừng ở việc ghép một mô hình có sẵn, mà phát triển thành quá trình nghiên cứu lặp, trong đó mỗi quyết định kỹ thuật xuất phát từ một vấn đề quan sát được[cite: 1].

1.3. Vấn đề nghiên cứu

Vấn đề nghiên cứu trung tâm của đề tài là: làm thế nào để xây dựng một hệ thống học sâu có khả năng phục hồi ảnh cũ bị suy thoái hỗn hợp – bao gồm vết nứt, vết xước (suy thoái cấu trúc) và phai màu, ám vàng, mất cân bằng màu (suy thoái màu sắc) – trong khi dữ liệu ảnh thật hầu như không có ground truth và các suy thoái có bản chất khác nhau?[cite: 1] Câu hỏi này dẫn đến nhiều vấn đề con cụ thể:

- **Hạn chế của mô hình end-to-end:** Tại sao một mạng U-Net duy nhất được huấn luyện với pixel loss (L1, SSIM) không thể phục hồi đồng thời cả vết nứt lẫn màu sắc một cách ổn định trên ảnh thật? Cần phân tích hiện tượng làm mờ (oversmoothing) và khoảng cách miền dữ liệu (domain gap)[cite: 1].
- **Thiết kế dữ liệu cho bài toán phân đoạn vết nứt:** Làm thế nào để tạo dữ liệu tổng hợp có ground-truth mask đủ chính xác và đa dạng, giúp mô hình học được đặc trưng của vết nứt thật? Cần xây dựng quy trình data-centric kết hợp mẫu vết nứt thực (Crack Bank), mô hình hóa bề mặt (heightmap, normal map) và mô phỏng chiếu sáng (Phong illumination)[cite: 1].
- **Lựa chọn kiến trúc phân đoạn phù hợp:** Vết nứt có cấu trúc mảnh, dài, dễ bị nhầm với cạnh vật thể hoặc nếp áo. Kiến trúc nào (Attention U-Net, ResNet-34 encoder) và hàm mất mát nào (BCE, Dice, Tversky) giúp tăng độ chính xác định vị (IoU, F1) mà vẫn giữ được độ nhạy với các vết nứt mờ?
- **Kết nối giữa segmentation và inpainting:** Mask tối ưu cho bài toán phân đoạn (bám sát ground-truth) chưa chắc là mask tối ưu cho inpainting. Cần có bước tinh chỉnh mặt nạ (mask refinement) và hybrid mask (kết hợp học sâu và xử lý ảnh truyền thống) để đảm bảo LaMa có đủ vùng ngữ cảnh bao phủ halo và bóng đổ[cite: 1].

- **Phục hồi màu sắc an toàn sau inpainting:** Ảnh sau LaMa vẫn có thể bị ám vàng, phai màu, tông sepia hoặc nhiều màu. Làm thế nào để thiết kế một module phục hồi màu chuyên biệt, vừa có khả năng hiệu chỉnh màu cục bộ và toàn cục, vừa không làm thay đổi nội dung cấu trúc ảnh? Cần một chiến lược kết hợp: OpenCV conservative preprocessing, U-Net dự đoán residual trong không gian Lab (có giới hạn biên độ), Lab protected blending, automatic chroma gate, và diagonal Color Correction Matrix (CCM) dựa trên gray-world[cite: 2].
- **Tích hợp và đánh giá toàn hệ thống mô-đun:** Làm thế nào để tổ chức một pipeline gồm bốn module (segmentation → inpainting → color restoration → face restoration tùy chọn) có thể chạy ổn định, dễ dàng thay thế từng module, đồng thời cho phép phân tích lỗi một cách rõ ràng (lỗi do segmenter, do mask refinement, do inpainting, do color model hay do face restoration)?[cite: 1]

Trong phạm vi đề tài, ảnh cũ được xem là ảnh RGB đầu vào có thể chứa nhiều loại suy thoái, nhưng trọng tâm triển khai là: (i) phát hiện và lấp vùng hư hỏng có cấu trúc (crack, scratch), (ii) phục hồi màu sắc còn tồn tại sau inpainting (không bao gồm colorization ảnh đen trắng). Các vấn đề như siêu phân giải, tô màu hoàn toàn, hoặc đánh giá bảo toàn danh tính khuôn mặt được xem là hướng mở rộng, không phải kết quả chính cần khẳng định trong phạm vi hiện tại[cite: 1][cite: 2].

1.4. Mục tiêu đề tài

Mục tiêu tổng quát của đề tài là nghiên cứu, thiết kế và xây dựng một hệ thống phục hồi ảnh cũ theo kiến trúc mô-đun, bao gồm bốn module chính: phát hiện vết nứt/vết xước (Module 1), inpainting bằng LaMa (Module 2), phục hồi màu sắc (Module 3) và tùy chọn phục hồi khuôn mặt (Module 4). Hệ thống hướng đến khả năng phân tích từng bước trung gian (ảnh đầu vào, mask dự đoán, mask tinh chỉnh, ảnh sau inpainting, ảnh sau phục hồi màu, ảnh sau face restoration) nhằm kiểm soát chất lượng và dễ dàng chẩn đoán lỗi[cite: 1][cite: 2]. Các mục tiêu cụ thể bao gồm:

1. **Xây dựng baseline end-to-end:** Phát triển mô hình U-Net cơ sở huấn luyện với L1 loss (và các biến thể loss) trên dữ liệu synthetic, làm điểm so sánh ban đầu và xác định giới hạn của hướng tiếp cận nguyên khối[cite: 1].
2. **Phân tích hạn chế của baseline:** Chỉ ra hiện tượng ảnh mờ (oversmoothing), mất chi tiết tần số cao và khoảng cách miền dữ liệu (domain gap) giữa synthetic và real – từ đó làm cơ sở chuyển sang pipeline mô-đun[cite: 1].
3. **Thiết kế data-centric cho crack/scratch segmentation:** Xây dựng quy trình sinh dữ liệu tổng hợp thực tế dựa trên Crack Bank (alpha mask), heightmap, normal map, mô hình chiếu sáng Phong và alpha blending, đồng thời chuẩn hóa tập ảnh thật có nhãn (118 cặp ảnh-mask) để huấn luyện và đánh giá[cite: 1].

4. **Huấn luyện và so sánh các segmenter:** Tiến hành chuỗi thực nghiệm R006–R014, so sánh hai cấu hình chính: R013 (custom lightweight Attention U-Net) và R014 (ResNet-34 encoder + U-Net decoder). Đánh giá dựa trên IoU, F1 và khả năng tích hợp với inpainting[cite: 1].
5. **Xây dựng hybrid mask và mask refinement:** Đề xuất cơ chế kết hợp mask học sâu (DL) và mask xử lý ảnh truyền thống (CV) cùng các phép toán hình thái học (closing, dilation) để tạo repair mask phù hợp với LaMa, giải quyết vấn đề mask quá hẹp hoặc quá rộng[cite: 1].
6. **Tích hợp LaMa pretrained làm backend inpainting:** Sử dụng LaMa dưới dạng mô hình đã huấn luyện sẵn, gọi qua subprocess wrapper để cô lập môi trường và tránh xung đột dependency. Không fine-tune LaMa trong phạm vi đồ án[cite: 1].
7. **Thiết kế và huấn luyện module phục hồi màu (Module 3):**
 - Xây dựng bộ sinh dữ liệu paired synthetic với profile suy giảm faded_color_v2 (giữ lại chroma có ích, gồm identity, mild yellow, faded old, sepia, hard degradation) và target là ảnh sạch[cite: 2].
 - Tiền xử lý nhất quán giữa train và inference: OpenCV conservative (NLMeans denoising, CLAHE trên kênh L, unsharp masking)[cite: 2].
 - Phát triển ColorRestorationUNet (U-Net, GroupNorm, LeakyReLU) dự đoán residual trong không gian Lab, với giới hạn thay đổi $L \leq 15$, $a, b \leq 40$ [cite: 2].
 - Thiết kế hàm loss tổng hợp (RGB L1, Lab L1, SSIM, histogram EMD, identity loss) để ưu tiên chroma nhưng vẫn bảo toàn cấu trúc[cite: 2].
 - Huấn luyện với AdamW, CosineAnnealingLR, early stopping, chọn checkpoint theo validation loss (epoch 42)[cite: 2].
8. **Triển khai inference an toàn cho module màu:**
 - Tiled inference (tile 256×256 , overlap 64, Hann-window blending) để xử lý ảnh full-resolution[cite: 2].
 - Lab protected blending ($s_L = 0.35$, $s_{ab} = 0.65$) và automatic chroma gate (giảm cường độ khi ảnh gần grayscale) nhằm tránh over-restoration[cite: 2].
 - Áp dụng diagonal Color Correction Matrix (CCM) dựa trên gray-world với giới hạn gain $\pm 15\%$ và strength 45% để hiệu chỉnh toàn cục nhẹ nhàng[cite: 2].
9. **Tích hợp module phục hồi khuôn mặt tùy chọn (Module 4):** Sử dụng CodeFormer với RetinaFace làm bộ phát hiện, giữ ở chế độ optional, có cảnh báo rủi ro hallucination và không cam kết bảo toàn danh tính[cite: 1].
10. **Tổ chức hệ thống suy luận và kiểm thử:** Xây dựng CLI (command-line interface), giao diện Gradio demo, readiness checker để kiểm tra checkpoint và dependency, quản lý artifact ngoài Git bằng manifest (SHA256), và các smoke/regression test (Demo3) nhằm đảm bảo tính nhất quán của pipeline[cite: 1].

1.5. Phạm vi thực hiện

Đề tài tập trung vào các khía cạnh cốt lõi của phục hồi ảnh cũ: (i) phát hiện và lấp vùng hư hỏng có cấu trúc (vết nứt, vết xước), (ii) phục hồi màu sắc sau inpainting. Do giới hạn về thời gian, dữ liệu có nhãn và tài nguyên GPU, một số module nâng cao (ví dụ: fine-tune inpainting backbone, colorization ảnh đen trắng, super-resolution) không nằm trong phạm vi đánh giá chính[cite: 1][cite: 2]. Báo cáo phân biệt rõ giữa thành phần đã triển khai, thành phần tích hợp ở mức tùy chọn và thành phần thuộc hướng phát triển tiếp theo[cite: 1].

Nhóm chức năng	Cách trình bày trong báo cáo
Mô hình cơ sở end-to-end	Dùng để phân tích giới hạn và làm baseline ban đầu; không xem là mô hình vận hành cuối cùng[cite: 1].
Data-centric degradation (crack/scratch)	Trình bày như thành phần quan trọng của phương pháp dữ liệu, giúp giảm khoảng cách giữa dữ liệu tổng hợp và ảnh cũ thật[cite: 1].
Crack/Scratch Segmentation (R013/R014)	Trình bày chi tiết kiến trúc, loss, lineage thực nghiệm và kết quả so sánh giữa các checkpoint[cite: 1].
Hybrid Mask và repair_wide_v1	Trình bày như bước hậu xử lý thực tế giúp mask phù hợp hơn với inpainting, đặc biệt khi mask dự đoán quá hẹp[cite: 1].
LaMa Inpainting	Chỉ khẳng định tích hợp pretrained backend; không khẳng định fine-tune LaMa trong phạm vi đồ án[cite: 1].
colorrestoreColor Restoration	Trình bày như module phục hồi màu sau LaMa: dữ liệu synthetic với profile faded_color_v2, OpenCV conservative preprocessing, U-Net dự đoán Lab residual, loss tổng hợp, tiled inference, Lab protected blending, chroma gate và CCM[cite: 2].
Face Restoration (CodeFormer)	Trình bày như module tùy chọn; nhấn mạnh rủi ro hallucination và không cam kết bảo toàn danh tính[cite: 1].
Colorization ảnh đen trắng và Super-resolution	Đưa vào phần hạn chế và hướng phát triển, không trình bày như kết quả chính đã triển khai[cite: 1][cite: 2].
LPIPS/FID quy mô lớn	Đưa vào protocol hoặc future work; không trình bày như kết quả đã đo đầy đủ[cite: 1].

Bảng 1.1: Phạm vi thực hiện và cách diễn giải trong báo cáo (cập nhật có module phục hồi màu)

1.6. Đóng góp chính của đề tài

Đóng góp của đề tài không nằm ở việc đề xuất một kiến trúc hoàn toàn mới thay thế các mô hình hiện đại, mà nằm ở việc xây dựng một hệ thống mô-đun hoàn chỉnh (gồm 4 module: segmentation, inpainting, color restoration, face restoration tùy chọn) phù hợp với điều kiện đồ án, có khả năng giải thích, kiểm thử và mở rộng[cite: 1][cite: 2]. Các đóng góp chính bao gồm:

- **Phân tích thực nghiệm giới hạn của mô hình end-to-end:** Chỉ ra hiện tượng làm mờ (oversmoothing) và khoảng cách miền dữ liệu (domain gap) khi áp dụng U-Net với pixel loss cho ảnh cũ thật, từ đó làm cơ sở chuyển sang pipeline mô-đun[cite: 1].

- **Thiết kế quy trình sinh dữ liệu vết nứt (crack/scratch) dạng data-centric:** Sử dụng Crack Bank, heightmap, normal map, mô hình chiếu sáng Phong và alpha blending để tạo paired data gần với ảnh cũ thật hơn, giảm khoảng cách giữa suy thoái tổng hợp và thực tế[cite: 1].
- **Huấn luyện và đánh giá có hệ thống các segmenter:** Xây dựng chuỗi thực nghiệm R006–R014, so sánh hai cấu hình R013 (custom lightweight Attention U-Net) và R014 (ResNet-34 encoder) trên cùng split dữ liệu thật (118 cặp), chỉ ra trade-off giữa segmentation accuracy và hình thái mask phù hợp cho inpainting[cite: 1].
- **Đề xuất hybrid mask và mask refinement:** Kết hợp mask học sâu (DL) và mask xử lý ảnh truyền thống (CV) cùng các phép toán hình thái học (closing, dilation) để tạo repair mask bao phủ vùng halo và bóng đổ, cải thiện chất lượng inpainting[cite: 1].
- **Tích hợp pretrained LaMa làm backend inpainting:** Gọi LaMa qua subprocess wrapper, cô lập môi trường, tránh xung đột dependency, cho phép dễ dàng thay thế backend trong tương lai[cite: 1].
- **Xây dựng module phục hồi màu chuyên biệt (Module 3):**
 - Thiết kế bộ sinh dữ liệu paired synthetic với profile suy giảm faded_color_v2 (giữ lại chroma có ích, gồm identity, mild yellow, faded old, sepia, hard) và target là ảnh sạch[cite: 2].
 - Tiền xử lý nhất quán (OpenCV conservative: NLMeans, CLAHE trên kênh L, unsharp masking) để giảm nhiễu và tăng tương phản mà không ảnh hưởng đến cấu trúc[cite: 2].
 - Phát triển ColorRestorationUNet (U-Net, GroupNorm, LeakyReLU) dự đoán residual trong không gian Lab với giới hạn biên độ $L \leq 15$, $a, b \leq 40$, giúp tách bạch luminance và chroma[cite: 2].
 - Đề xuất hàm loss tổng hợp (RGB L1, Lab L1, SSIM, histogram EMD, identity loss) để ưu tiên phục hồi màu nhưng vẫn bảo toàn cấu trúc và hành vi pass-through cho ảnh đã tốt[cite: 2].
 - Triển khai tiled inference (tile 256, overlap 64, Hann-window) để xử lý ảnh full-resolution[cite: 2].
 - Đưa ra cơ chế inference control an toàn: Lab protected blending ($s_L = 0.35$, $s_{ab} = 0.65$) và automatic chroma gate (giảm cường độ khi ảnh gần grayscale)[cite: 2].
 - Áp dụng conservative diagonal CCM dựa trên gray-world với giới hạn gain $\pm 15\%$ và strength 45% để hiệu chỉnh toàn cục nhẹ nhàng, tránh làm thay đổi phong cách ảnh[cite: 2].
- **Tích hợp CodeFormer làm module phục hồi khuôn mặt tùy chọn (Module 4):** Có cơ chế bật/tắt, phát hiện khuôn mặt bằng RetinaFace, kèm cảnh báo rủi ro hallucination và không cam kết bảo toàn danh tính[cite: 1].

- **Tổ chức hệ thống suy luận hoàn chỉnh:** Xây dựng CLI, giao diện Gradio demo, readiness checker kiểm tra checkpoint/dependency, quản lý artifact ngoài Git bằng manifest (SHA256), và các smoke/regression test (Demo3) đảm bảo tính nhất quán của pipeline sau refactor[cite: 1].

1.7. Cấu trúc báo cáo

Báo cáo được tổ chức thành tám chương, phản ánh đầy đủ quá trình phát triển từ baseline đến hệ thống hoàn chỉnh với bốn module[cite: 1][cite: 2].

- **Chương 1: Giới thiệu** – Bối cảnh, động cơ, vấn đề nghiên cứu, mục tiêu, phạm vi và đóng góp của đề tài.
- **Chương 2: Cơ sở lý thuyết và công trình liên quan** – Trình bày các nền tảng toán học và học sâu cho image restoration, segmentation, inpainting, phục hồi màu (Lab, loss, CCM), và các công trình liên quan (Bringing Old Photos Back to Life, LaMa, CodeFormer).
- **Chương 3: Phân tích bài toán và quá trình phát triển phương pháp** – Phân tích thất bại của baseline end-to-end, phát hiện domain gap, chuyển hướng sang data-centric segmentation và real-domain fine-tuning; nêu rõ lý do cần module phục hồi màu riêng.
- **Chương 4: Hệ thống phục hồi ảnh cũ đề xuất** – Mô tả chi tiết pipeline 4 module: segmentation (R013/R014), mask refinement, LaMa inpainting, color restoration (dữ liệu, preprocessing, kiến trúc, loss, inference control, CCM), và CodeFormer tùy chọn.
- **Chương 5: Thiết lập thực nghiệm và triển khai** – Môi trường, dữ liệu (crack/scratch và color), split, tiền xử lý, siêu tham số huấn luyện, quản lý checkpoint, CLI, UI, kiểm thử.
- **Chương 6: Kết quả thực nghiệm và thảo luận** – Kết quả segmentation (R013 vs R014), restoration check, đánh giá định tính module màu, phân tích lỗi theo module, so sánh với baseline.
- **Chương 7: Hạn chế và hướng phát triển** – Phân tích các hạn chế về dữ liệu (quy mô nhỏ, domain gap), mô hình (segmenter, LaMa chưa fine-tune, CCM dựa trên gray-world), đánh giá (thiếu benchmark lớn), và đề xuất lộ trình ưu tiên.
- **Chương 8: Tổng kết và kết luận** – Tóm tắt các kết quả chính, khẳng định tính khả thi của pipeline mô-đun, nhấn mạnh bài học về dữ liệu và mask morphology, và kết luận chung.

Chương 2

Cơ sở lý thuyết và công trình liên quan

2.1. Tổng quan về bài toán Phục hồi ảnh cũ và phân loại suy thoái

2.1.1. Bản chất toán học của bài toán nghịch đảo (Inverse Problem)

Phục hồi ảnh cũ (Old Photo Restoration) về bản chất là việc giải quyết một bài toán nghịch đảo không chỉnh (ill-posed inverse problem). Dưới góc độ toán học, quá trình suy thoái của một bức ảnh có thể được mô hình hóa tổng quát qua phương trình:

$$\mathbf{y} = \mathcal{D}(\mathbf{x}) + \mathbf{n} \quad (2.1)$$

Trong đó, $\mathbf{x}$ là ảnh gốc nguyên bản chưa bị suy thoái, $\mathbf{y}$ là ảnh cũ thu được trong thực tế, $\mathcal{D}(\cdot)$ là hàm suy thoái phi tuyến tính (bao gồm mờ, phai màu, đứt gãy cấu trúc không gian do vết nứt), và $\mathbf{n}$ là nhiễu phụ trợ (additive noise).

Mục tiêu của bài toán là tìm một hàm ánh xạ ngược $\mathcal{F}_\theta \approx \mathcal{D}^{-1}$ được tham số hóa bởi θ (trọng số của mạng nơ-ron) sao cho $\hat{\mathbf{x}} = \mathcal{F}_\theta(\mathbf{y})$ xấp xỉ gần nhất với $\mathbf{x}$. Vì $\mathcal{D}$ thường làm mất thông tin và không có nghịch đảo duy nhất, không gian nghiệm của bài toán là vô hạn. Đây là lý do các hệ thống Học sâu phải sử dụng các tiên nghiệm (priors) mạnh mẽ để giới hạn không gian tìm kiếm, đảm bảo ảnh đầu ra tuân theo phân phối tự nhiên của thị giác con người.

2.1.2. Phân loại suy thoái trong ảnh cũ

Hàm $\mathcal{D}$ trong ảnh cũ là một hàm suy thoái hỗn hợp (mixed degradation), có thể phân tách thành bốn thành phần cấu trúc chính, chi phối thiết kế của các hệ thống AI hiện đại:

Nhóm suy thoái	Ví dụ điển hình	Đặc trưng Không gian & Miền tần số	Chiến lược tiếp cận
Phi cấu trúc	Nhiều hạt, mờ, ố vàng	Tác động lên toàn bộ ma trận điểm ảnh, làm thay đổi phân phối tần số thấp và cao một cách đồng đều.	Lọc nhiễu toàn cục bằng ResBlocks.
Có cấu trúc (Structured)	Vết nứt (Crack), vết xước (Scratch), mốc, rách giấy	Phá hủy hoàn toàn tensor thông tin tại các vùng cục bộ, tạo ra các gradient biên cực lớn (high contrast edges).	Phân đoạn (Segmentation) định vị tọa độ, kết hợp Inpainting lấp cấu trúc.
Màu sắc (Color)	Ám vàng, phai màu, tông sepia, mất cân bằng kênh (channel cast), chói sáng không đều	Tác động chủ yếu lên phân phối chroma (kênh a,b trong Lab), có thể toàn cục hoặc cục bộ; luminance (L) ít thay đổi hơn.	Phục hồi màu trong không gian Lab (dự đoán residual), kết hợp cân bằng histogram và hiệu chỉnh toàn cục (CCM).
Khuôn mặt	Mất chi tiết định danh (mắt, mũi, môi)	Thuộc về đa tạp dữ liệu có cấu trúc topology độ chiều cao, nhạy cảm với hệ thống thị giác người.	Sử dụng không gian tiềm ẩn mã hóa trước như VQVAE.

Bảng 2.1: Phân tích đặc trưng toán học và hình thái của các dạng suy thoái ảnh cũ (bổ sung nhóm màu sắc)

2.2. Cơ sở lý thuyết về Phân đoạn vùng hư hỏng (Segmentation)

2.2.1. Mạng nơ-ron tích chập (CNN) và Giới hạn vùng cảm thụ (Receptive Field)

Mạng nơ-ron tích chập (CNN) dựa trên phép toán tích chập rời rạc 2D để trích xuất đặc trưng không gian. Phương trình cơ sở cho một điểm ảnh ở kênh đầu ra thứ k là:

$$\mathbf{Y}_k(i,j) = \sum_{c=1}^{C_{in}} \sum_m \sum_n \mathbf{X}_c(i+m,j+n) \mathbf{W}_{k,c}(m,n) + b_k$$

(2.2)

Mặc dù CNN cực kỳ xuất sắc trong việc nắm bắt tính định xứ (locality), chúng bị giới hạn bởi Vùng cảm thụ hiệu dụng (Effective Receptive Field - ERF). Đối với các vết nứt kéo dài xuyên suốt bức ảnh, một lớp tích chập với kernel 3×3 không thể nắm bắt được toàn cục cấu trúc. Điều này buộc các kiến trúc phân đoạn phải sử dụng cơ chế giảm lấy mẫu (downsampling) để mở rộng ERF, điển hình là mạng U-Net.

2.2.2. Cơ chế Attention Gate và Deep Supervision trong bộ giải mã

Kiến trúc U-Net giải quyết vấn đề mất mát độ phân giải không gian bằng các kết nối tắt (skip connections) từ Encoder sang Decoder. Tuy nhiên, trong bài toán phân đoạn vết nứt, các skip connections này vô tình mang theo nhiễu nền (background noise như nếp áo, vân giấy) đi vào bộ giải mã.

Để khắc phục, Attention Gate (AG) được áp dụng. Về mặt toán học, AG tính toán ma trận hệ số chú

ý $\alpha \in [0, 1]$ tại mỗi điểm ảnh i bằng cách kết hợp đặc trưng nông từ skip connection $\mathbf{x}_i^l$ và tín hiệu điều khiển (gating signal) $\mathbf{g}_i$ từ tầng sâu hơn:

$$\alpha_i = \sigma \left(\mathbf{W}_{attn}^T (\text{ReLU}(\mathbf{W}_x^T \mathbf{x}_i^l + \mathbf{W}_g^T \mathbf{g}_i + b_g)) + b_{attn} \right) \quad (2.3)$$

Đầu ra của AG là $\hat{\mathbf{x}}_i^l = \alpha_i \odot \mathbf{x}_i^l$, giúp triệt tiêu các vector đặc trưng không thuộc vùng vết nứt trước khi thực hiện phép nối kết (concatenation). Kết hợp cùng cơ chế Giám sát sâu (Deep Supervision), hàm loss được tính gradient tại nhiều mức scale của Decoder, giúp mô hình học được từ vi nứt (micro-cracks) đến các dải nứt lớn.

2.2.3. Kiểm soát tính toàn vẹn dữ liệu (Data Integrity) trong huấn luyện phân đoạn

Một nguyên tắc học máy tối quan trọng để đảm bảo tính hợp lệ của hàm mất mát và các chỉ số (metrics) là ngăn chặn tuyệt đối rò rỉ dữ liệu (Data Leakage). Trong quá trình xây dựng đường ống dữ liệu (data pipeline) cho bài toán này, quy trình phân chia dữ liệu (Data Splitting) thành các tập Train, Validation và Test bắt buộc phải được thực hiện triệt để **trước** mọi bước tiền xử lý (preprocessing) hay tổng hợp nhiễu (như augmentation, heightmap synthesis hay alpha blending). Việc đảm bảo phân tách không gian đa tập dữ liệu gốc trước khi biến đổi giúp khẳng định các kết quả IoU hay F1 thu được là khả năng tổng quát hóa thực sự (true generalization) chứ không phải do mô hình nội suy từ sự rò rỉ đặc trưng của tập kiểm thử.

2.2.4. Động lực học của các Hàm mất mát mất cân bằng lớp

Bài toán phân đoạn vết nứt đối mặt với sự mất cân bằng lớp cực đoan (class imbalance), nơi pixel nền áp đảo hoàn toàn pixel vết nứt. Nếu sử dụng Binary Cross Entropy (BCE) thông thường, gradient bị chi phối bởi lớp đa số, khiến mạng hội tụ về một nghiệm tầm thường (dự đoán toàn bộ là nền).

Hệ thống giải quyết sự cố này bằng cách kết hợp Tversky Loss. Dựa trên chỉ số Tversky, hàm loss này kiểm soát hình phạt lên các False Negative (FN) và False Positive (FP) thông qua hai siêu tham số α và β :

$$\mathcal{L}_{\text{Tversky}} = 1 - \frac{\sum_{i=1}^N p_{ic} g_{ic}}{\sum_{i=1}^N p_{ic} g_{ic} + \alpha \sum_{i=1}^N p_{i\bar{c}} g_{ic} + \beta \sum_{i=1}^N p_{ic} g_{i\bar{c}}} \quad (2.4)$$

Bằng cách thiết lập $\beta > \alpha$, gradient của mạng bị ép buộc phải phạt cực kỳ nặng đối với việc bỏ sót các điểm ảnh vết nứt (FN), từ đó tối đa hóa hệ số Recall, tạo ra một mặt nạ (mask) bao phủ an toàn cho bước inpainting phía sau.

2.3. Cơ sở lý thuyết về Lấp vùng ảnh hỏng và Phục hồi (Restoration)

Bài toán phục hồi ảnh cũ sau khi đã có mask vùng hư hỏng đòi hỏi hai khả năng chính: (i) lấp đầy vùng mất dữ liệu có cấu trúc (inpainting) và (ii) khôi phục chất lượng màu sắc cũng như các chi tiết

khuôn mặt bị suy thoái. Trong hệ thống đề xuất, hai nhiệm vụ này được tách thành Module 2 (LaMa inpainting) và Module 3+4 (phục hồi màu + face restoration).

2.3.1. Inpainting với LaMa và Fast Fourier Convolution

Để lấp đầy các vùng hư hỏng lớn (vết nứt, vết xước dài) một cách nhất quán, mô hình cần hiểu được các họa tiết lặp lại ở khoảng cách xa. Kiến trúc LaMa (Large Mask Inpainting) giải quyết vấn đề này bằng Fast Fourier Convolution (FFC).

Thay vì chỉ tích chập trên miền không gian (spatial domain) với receptive field giới hạn, FFC thực hiện biến đổi Fourier 2D thực (Real FFT) để chuyển một nửa số kênh của tensor đặc trưng sang miền tần số (frequency domain):

$$\mathbf{Z}_{freq} = \mathcal{F}(\mathbf{Z}_{spatial}) \quad (2.5)$$

Trong miền tần số, mỗi điểm ảnh ảnh hưởng đến **tất cả** các điểm còn lại. Sau khi thực hiện tích chập 1×1 trên phổ tần số, mô hình dùng biến đổi Fourier ngược để khôi phục không gian gốc. Nhờ vậy, LaMa đạt được vùng cảm thụ hiệu dụng bao phủ toàn bộ ảnh (image-wide ERF) ngay từ những lớp đầu tiên.

Để tránh hiện tượng ảnh bị làm mờ (oversmoothing) do tối ưu hóa L1/L2, LaMa được huấn luyện với cơ chế sinh đối kháng (GAN). PatchGAN Discriminator D tính ma trận xác suất phân biệt thật/giả trên từng patch cục bộ. Hàm Hinge Adversarial Loss:

$$\mathcal{L}_D = \mathbb{E}_{\mathbf{x}} [\text{ReLU}(1 - D(\mathbf{x}))] + \mathbb{E}_{\mathbf{z}, \mathbf{m}} [\text{ReLU}(1 + D(G(\mathbf{z}, \mathbf{m}))) \quad (2.6)$$

$$\mathcal{L}_G = -\mathbb{E}_{\mathbf{z}, \mathbf{m}} [D(G(\mathbf{z}, \mathbf{m}))] \quad (2.7)$$

Kết hợp với **Perceptual Loss** (khoảng cách L1 giữa các feature map của VGG-19) giúp bộ sinh G tái tạo không chỉ pixel mà còn cả đặc trưng ngữ nghĩa (nếp vải, vân gỗ, kết cấu giấy).

2.3.2. Phục hồi màu sắc trong không gian Lab

Sau inpainting, ảnh có thể còn tồn tại các suy thoái màu như ám vàng, phai màu, tông sepia, mất cân bằng kênh. Module phục hồi màu được thiết kế riêng với chiến lược “bảo thủ có kiểm soát”.

Phục hồi màu dựa trên Lab residual: Không gian màu CIELAB (Lab) tách biệt luminance (L) khỏi chroma (a, b), phù hợp để xử lý màu mà không ảnh hưởng đến cấu trúc. Mô hình U-Net dự đoán ba residual $\mathbf{r} = (r_L, r_a, r_b)$ với đầu ra bị chặn trong $[-1, 1]$ nhờ hàm tanh. Quá trình tái tạo:

$$\begin{aligned} L_{\text{out}} &= \text{clamp}(L_{\text{in}} + 15 r_L, 0, 100) \\ a_{\text{out}} &= \text{clamp}(a_{\text{in}} + 40 r_a, -128, 127) \\ b_{\text{out}} &= \text{clamp}(b_{\text{in}} + 40 r_b, -128, 127) \end{aligned} \quad (2.8)$$

Giới hạn 15 cho L và 40 cho a, b được xác định từ thực nghiệm để tránh thay đổi quá mạnh.

Hàm mất mát tổng hợp: Để ưu tiên phục hồi chroma nhưng vẫn bảo toàn cấu trúc và hành vi pass-through, module sử dụng loss kết hợp:

$$\mathcal{L}_{\text{total}} = 0.5\mathcal{L}_{\text{RGB}} + 0.5\mathcal{L}_L + 1.0\mathcal{L}_{ab} + 0.2\mathcal{L}_{\text{SSIM}} + 0.1\mathcal{L}_{\text{hist}} + 0.2\mathcal{L}_{\text{identity}} \quad (2.9)$$

Trong đó: - $\mathcal{L}_{\text{RGB}}, \mathcal{L}_L, \mathcal{L}_{ab}$ là L1 loss trên từng không gian. - $\mathcal{L}_{\text{SSIM}}$ bảo toàn cấu trúc cục bộ. - $\mathcal{L}_{\text{hist}}$ là Earth Mover’s Distance (EMD) giữa histogram của kênh a, b , giúp căn chỉnh phân phối màu toàn cục. - $\mathcal{L}_{\text{identity}}$ chỉ áp dụng trên các mẫu không suy giảm (identity samples) để học hành vi giữ nguyên đầu vào.

Kiểm soát suy luận (Inference Control): Raw model output có thể gây oversaturation hoặc biến đổi luminance quá mức. Do đó, pipeline áp dụng: - **Lab protected blending:**

$$\begin{aligned} L_{\text{controlled}} &= L_{\text{quality}} + s_L(L_{\text{model}} - L_{\text{quality}}), \quad s_L = 0.35 \\ ab_{\text{controlled}} &= ab_{\text{quality}} + s_{ab}(ab_{\text{model}} - ab_{\text{quality}}), \quad s_{ab} = 0.65 \end{aligned} \quad (2.10)$$

- **Automatic chroma gate:** Dựa trên mean chroma của ảnh quality, tự động giảm cường độ chroma khi ảnh gần grayscale (mean chroma $< 4 \rightarrow$ strength 0.20). - **Conservative diagonal CCM:** Cuối pipeline, ước lượng gray-world trên các pixel trung tính (mid-tone, saturation thấp), giới hạn gain trong 1 ± 0.15 và chỉ áp dụng 45% mức điều chỉnh, giúp hiệu chỉnh toàn cục nhẹ nhàng mà không làm thay đổi phong cách ảnh.

2.3.3. Phục hồi khuôn mặt qua prior không gian tiềm ẩn

Khi vùng nứt hoặc suy thoái ảnh hưởng đến vùng mắt, mũi, miệng, inpainting thông thường thiếu kiến thức giải phẫu, dễ tạo ra cấu trúc dị dạng. CodeFormer giải quyết bằng cách sử dụng một từ điển mã rời rạc (VQVAE Codebook) $\mathcal{C} = \{c_k \in \mathbb{R}^d\}_{k=1}^K$ đã được học trước từ tập ảnh khuôn mặt chất lượng cao (FFHQ). Quá trình lượng tử hóa:

$$z_q = \arg \min_{c_k \in \mathcal{C}} \|z_h - c_k\|_2 \quad (2.11)$$

Mạng Transformer sau đó kết hợp các token rời rạc để phục dựng khuôn mặt, biến bài toán từ “dự đoán pixel mù mờ” thành “tra cứu và ghép nối các thành phần giải phẫu chuẩn”. Trong hệ thống, module này được giữ ở chế độ **tùy chọn (optional)**, kèm cảnh báo rõ về rủi ro hallucination (sinh chi tiết không có trong ảnh gốc) và chưa đánh giá bảo toàn danh tính.


2.4. Các công trình nghiên cứu liên quan

Công trình *Bringing Old Photos Back to Life (CVPR 2020)* của Wan et al. là một bước ngoặt trong lĩnh vực phục hồi ảnh cũ. Công trình này lần đầu tiên toán học hóa khái niệm "Domain Gap" giữa không gian suy thoái nhân tạo và không gian suy thoái thực tế. Dựa trên phân tích đó, nhóm tác giả đề xuất sử dụng VAE (Variational Autoencoder) để ánh xạ hai miền dữ liệu về cùng một không gian ẩn (latent space). Dù cách tiếp cận khác nhau, nguyên lý phân rã (decomposition) bài toán thành các nhánh xử lý suy thoái cấu trúc và phi cấu trúc của công trình này là nguồn cảm hứng trực tiếp cho tư duy thiết kế kiến trúc Mô-đun và đường ống kiểm soát dữ liệu nghiêm ngặt trong báo cáo của đề tài.

Chương 3

Hệ thống phục hồi ảnh cũ đề xuất

3.1. Kiến trúc tổng quan của pipeline đề xuất



Hình 3.1: Kiến trúc pipeline phục hồi ảnh cũ đã tối ưu diện tích.

Hệ thống phục hồi ảnh cũ được thiết kế theo cấu trúc phân rã chức năng (Functional Decomposition), bao gồm bốn module chính vận hành nối tiếp nhau. Hình 3.1 minh họa luồng dữ liệu tổng thể. Cho một ảnh đầu vào $\mathbf{I}_{in} \in \mathbb{R}^{H \times W \times 3}$ (ảnh RGB đã số hóa), luồng dữ liệu được định nghĩa như sau:

1. **Module 1 – Phân đoạn vết nứt / vết xước (Crack/Scratch Segmentation):** Ảnh đầu vào được resize về 512×512 và chuẩn hóa theo cấu hình của segmenter được chọn. Hệ thống cung cấp hai option:

- **Attention U-Net:** không sử dụng pretrained backbone, preprocessing chia 255.0.
- **ResNet-34 encoder (pretrained ImageNet):** kết hợp U-Net decoder và Attention Gate, preprocessing theo ImageNet normalization.

Module này xuất ra probability map $\hat{\mathbf{P}} \in [0, 1]^{512 \times 512}$, sau đó được ngưỡng hóa (threshold) để tạo binary mask.

2. **Bước trung gian – Tinh chỉnh mặt nạ lai (Hybrid Mask Refinement):** Binary mask từ segmenter được kết hợp với mask từ xử lý ảnh truyền thống (CV) như Canny, CLAHE + blackhat, sau đó qua các phép toán hình thái học (closing, dilation) để tạo ra **repair mask** $\mathbf{M}_{refined}$. Bước này đảm bảo mask đủ rộng bao phủ halo, bóng đổ và vùng chuyển tiếp quanh vết nứt, phù hợp với yêu cầu của inpainting.

3. **Module 2 – Inpainting vùng hư hỏng (LaMa Inpainting):** Sử dụng ảnh gốc $\mathbf{I}_{in}$ (đã resize) và repair mask $\mathbf{M}_{refined}$ làm đầu vào cho mô hình LaMa pretrained $\mathcal{F}_{LaMa}$. LaMa dựa trên Fast Fourier Convolution (FFC) và được gọi qua subprocess wrapper để cô lập môi trường. Kết quả là ảnh $\mathbf{I}_{inpainted} = \mathcal{F}_{LaMa}(\mathbf{I}_{in}, \mathbf{M}_{refined})$, trong đó vùng tương ứng với mask được lấp đầy bằng nội dung hợp lý về mặt thị giác.

4. **Module 3 – Phục hồi màu sắc (Color Restoration):** Ảnh sau inpainting còn có thể tồn tại ám vàng, phai màu, tông sepia. Module này thực hiện:

- Tiền xử lý OpenCV conservative (NLMeans denoising, CLAHE trên kênh L, unsharp masking).
- ColorRestorationUNet dự đoán residual trong không gian Lab với giới hạn $L \leq 15, a, b \leq 40$.
- Tái tạo ảnh, sau đó áp dụng Lab protected blending ($s_L = 0.35, s_{ab} = 0.65$) và automatic chroma gate.
- Cuối cùng, diagonal Color Correction Matrix (CCM) dựa trên gray-world (giới hạn gain $\pm 15\%$, strength 45%) để hiệu chỉnh toàn cục nhẹ nhàng.

Kết quả là ảnh $\mathbf{I}_{color}$.

5. **Module 4 – Phục hồi khuôn mặt tùy chọn (CodeFormer):** Ảnh $\mathbf{I}_{color}$ được đưa qua bộ phát hiện khuôn mặt RetinaFace. Nếu phát hiện có khuôn mặt và người dùng bật tùy chọn, hệ thống kích hoạt CodeFormer $\mathcal{F}_{face}$ (dựa trên VQVAE codebook lookup) để tăng cường chi tiết vùng mặt, tạo ra ảnh $\mathbf{I}_{final}$. Module này có cảnh báo rõ về rủi ro hallucination và không cam kết bảo toàn danh tính. Trong trường hợp không bật hoặc không phát hiện khuôn mặt, $\mathbf{I}_{final} = \mathbf{I}_{color}$.

3.1.1. Mô hình hóa bề mặt vật lý không gian ba chiều

Hệ thống tính toán bản đồ độ cao (Heightmap) $H(x, y)$ dựa trên phép biến đổi khoảng cách từ mặt nạ $\mathbf{C}_k$. Từ mặt phẳng độ cao này, Bản đồ pháp tuyến (Normal Map) $\mathbf{N}(x, y) \in \mathbb{R}^3$ được tính bằng phương pháp sai phân hữu hạn (Finite Differences).

3.1.2. Giải lập mô hình chiếu sáng Phong và Alpha Blending

Hệ thống giải mô hình phản xạ Phong (Phong Illumination Model) dựa trên vector pháp tuyến $\mathbf{N}$, hướng sáng $\mathbf{L}$, và hướng quan sát $\mathbf{V}$. Cuối cùng, phương trình Alpha Blending phi tuyến được áp dụng để hợp nhất vết nứt vào ảnh sạch $\mathbf{I}_{clean}$:

$$\mathbf{I}_{syn} = \alpha_{blend} \odot I(x, y) + (1 - \alpha_{blend}) \odot \mathbf{I}_{clean} \quad (3.1)$$


3.2. Quy trình tổng hợp dữ liệu vết nứt nâng cao (Data-centric Pipeline)

Sự thành bại của mô hình học sâu phụ thuộc vào đa tạp dữ liệu (data manifold) mà nó được huấn luyện. Đề tài áp dụng chiến lược Data-centric, trong đó quy trình sinh dữ liệu được mô hình hóa dựa trên quang học vật lý.

Lưu ý về tính toàn vẹn đường ống (Pipeline Integrity): Mọi thuật toán tổng hợp nhiễu, bao gồm mô hình hóa bề mặt và đổ bóng dưới đây, chỉ được kích hoạt *sau khi* tập dữ liệu gốc (DIV2K, FFHQ) đã được thực hiện phép chia tách (Data Splitting). Nguyên tắc này đảm bảo mô hình không bị rò rỉ dữ liệu (Data Leakage) giữa các tập Train và Test.

Data-Centric Degradation Pipeline

Tạo cặp dữ liệu: degraded image + ground-truth mask + clean target



Hình 3.2: Sơ đồ Degradation pipeline tạo dữ liệu training từ ảnh sạch và Crack Bank

3.2.1. Khai thác dữ liệu nền và xây dựng Crack Bank

Thay vì dùng nhiễu ngẫu nhiên, hệ thống trích xuất các họa tiết vết nứt thực tế từ tập CrackForest để xây dựng một bộ từ điển vết nứt (Crack Bank) $\mathcal{B} = \{\mathbf{C}_1, \mathbf{C}_2, \dots, \mathbf{C}_K\}$. Mỗi phần tử $\mathbf{C}_k$ là một ma trận nhị phân (alpha mask) lưu trữ cấu trúc hình học cấu trúc (topology) của sự đứt gãy.

3.2.2. Mô hình hóa bề mặt vật lý không gian ba chiều (Heightmap & Normal Map)

Một vết nứt trên giấy không phải là đường thẳng 2D mà là một rãnh nứt 3D. Hệ thống tính toán bản đồ độ cao (Heightmap) $H(x, y)$ dựa trên phép biến đổi khoảng cách (Distance Transform) từ mặt nạ $\mathbf{C}_k$:

$$H(x, y) = 1 - \exp\left(-\frac{\mathcal{DT}(\mathbf{C}_k(x, y))^2}{2\sigma^2}\right) \quad (3.2)$$

Từ mặt phẳng độ cao này, Gradient không gian (Spatial Gradient) được tính bằng phương pháp sai phân hữu hạn (Finite Differences) để tạo ra Bản đồ pháp tuyến (Normal Map) $\mathbf{N}(x, y) \in \mathbb{R}^3$:

$$\mathbf{N}(x, y) = \frac{\left(-\frac{\partial H}{\partial x}, -\frac{\partial H}{\partial y}, 1\right)}{\sqrt{\left(\frac{\partial H}{\partial x}\right)^2 + \left(\frac{\partial H}{\partial y}\right)^2 + 1}} \quad (3.3)$$

Vector pháp tuyến $\mathbf{N}$ chỉ định hướng bề mặt tại mỗi điểm, là cơ sở để giải phương trình chiếu sáng.

3.2.3. Giả lập mô hình chiếu sáng Phong và Alpha Blending

Để tạo ra hiệu ứng đổ bóng (shadow) dưới rãnh nứt và quầng sáng (halo) trên mép giấy, hệ thống giải mô hình phản xạ Phong (Phong Illumination Model). Cường độ ánh sáng $I(x, y)$ tại một điểm phụ thuộc vào vector pháp tuyến $\mathbf{N}$, vector hướng sáng $\mathbf{L}$, và vector quan sát $\mathbf{V}$:


$$I(x, y) = k_a I_a + k_d (\mathbf{L} \cdot \mathbf{N}) I_d + k_s (\mathbf{R} \cdot \mathbf{V})^n I_s \quad (3.4)$$

Trong đó, $\mathbf{R} = 2(\mathbf{L} \cdot \mathbf{N})\mathbf{N} - \mathbf{L}$ là vector phản xạ lý tưởng. Bằng cách điều chỉnh góc $\mathbf{L}$, hệ thống sinh ra vô số biến thể vết nứt có độ sáng/tối khác nhau từ cùng một mask gốc.

Cuối cùng, phương trình Alpha Blending phi tuyến được áp dụng để hợp nhất vết nứt vào ảnh sạch $\mathbf{I}_{clean}$:

$$\mathbf{I}_{syn} = \alpha_{blend} \odot I(x, y) + (1 - \alpha_{blend}) \odot \mathbf{I}_{clean} \quad (3.5)$$

3.3. Module 1: Phân đoạn vết nứt dựa trên Attention U-Net



Hai option: R013 (custom lightweight, preprocessing /255.0) | R014 (ResNet-34 encoder + pretrained, ImageNet norm)

Hình 3.3: Kiến trúc Module 1 với hai option R013 (custom lightweight Attention U-Net) và R014 (ResNet-34 + U-Net + AG). Hình minh họa cấu trúc chung của U-Net với Attention Gate và Deep Supervision.

3.3.1. Kiến trúc cơ sở: Custom lightweight Attention U-Net (R013)

Mô hình cơ sở cho phân đoạn là một biến thể Attention U-Net nhẹ, được thiết kế để hoạt động ổn định trong điều kiện tài nguyên hạn chế. Đầu vào của mạng là tensor $\mathbf{X} \in \mathbb{R}^{B \times 3 \times 512 \times 512}$ sau khi resize và chia cho 255.0 (chuẩn hóa về $[0, 1]$). Encoder gồm 4 khối tích chập, mỗi khối có hai lớp Conv2D (kernel 3×3 , padding giữ kích thước) kèm BatchNorm, ReLU và MaxPooling (stride 2). Số kênh tăng dần: 64, 128, 256, 512.

Decoder gồm 4 khối giải mã, bắt đầu bằng upsampling (ConvTranspose2d), sau đó concatenate với feature map từ encoder qua skip connection (có Attention Gate), rồi qua hai lớp Conv2D + BatchNorm + ReLU. Attention Gates được đặt ở ba mức skip connection cuối để lọc nhiễu nền. Deep Supervision được áp dụng với ba đầu ra phụ (tỉ lệ 1x, 2x, 4x downsampled) để tăng cường gradient cho các tầng sâu.

Hàm loss tổng hợp:

$$\mathcal{L}_{total} = \mathcal{L}_{BCE}(\hat{\mathbf{P}}_{final}, \mathbf{Y}) + \mathcal{L}_{Dice}(\hat{\mathbf{P}}_{final}, \mathbf{Y}) + \sum_{s \in \{2,4\}} \gamma_s \left(\mathcal{L}_{BCE}(\hat{\mathbf{P}}_s, \mathbf{Y}_s) + \mathcal{L}_{Dice}(\hat{\mathbf{P}}_s, \mathbf{Y}_s) \right) \quad (3.6)$$

với $\gamma_2 = 0.3, \gamma_4 = 0.1$. R013 hoạt động như segmenter mặc định (fallback/default) nhờ tính ổn định và nhẹ.

3.3.2. Thử nghiệm bóc tách: Nâng cấp bộ trích xuất đặc trưng với ResNet-34 (R014)

Nhằm cải thiện khả năng trích xuất đặc trưng, đặc biệt với các vết nứt mảnh trên nền phức tạp, nhóm thay thế encoder tự định nghĩa bằng kiến trúc ResNet-34. Mỗi khối dư (Residual Block) thực hiện ánh xạ:

$$\mathbf{Y} = \mathcal{F}(\mathbf{X}, \{\mathbf{W}_i\}) + \mathbf{X} \quad (3.7)$$

với $\mathcal{F}$ là chuỗi Conv2D–BatchNorm–ReLU. Encoder được khởi tạo với trọng số pretrained trên ImageNet. Input ảnh được resize về 512×512 và chuẩn hóa theo ImageNet: $\mathbf{x}_{norm} = (\mathbf{x}/255.0 - \boldsymbol{\mu})/\boldsymbol{\sigma}$ với $\boldsymbol{\mu} = [0.485, 0.456, 0.406]$, $\boldsymbol{\sigma} = [0.229, 0.224, 0.225]$.

Phần decoder và Attention Gate được giữ nguyên cấu trúc giống R013. Deep Supervision vẫn được sử dụng. Trong quá trình inference, mô hình được khởi tạo với `pretrained=False` và nạp trọng số từ checkpoint cục bộ. R014 cho thấy cải thiện rõ về IoU/F1 trên cùng split, nhưng yêu cầu chính sách mask (threshold 0.30 + dilation 3x3) để phù hợp với inpainting. Do đó, R014 được xem là option nâng cao (recommended demo option).

3.4. Nhánh tinh chỉnh mặt nạ lai (Hybrid Mask Refinement)


Trong môi trường thực tế, mô hình học sâu (DL) có xu hướng bảo thủ (high precision, low recall) đối với các vi nứt (micro-cracks). Ngược lại, kỹ thuật thị giác máy tính cổ điển (CV) như Canny Edge Detector dễ dàng bắt được các vi nứt nhưng lại sinh ra quá nhiều nhiễu giả (False Positives).

Đề tài đề xuất giải pháp **Mặt nạ lai (Hybrid Mask)**, kết hợp sức mạnh của cả hai. Giả sử $\mathbf{M}_{DL}$ là mặt nạ học sâu (đã qua ngưỡng cut-off) và $\mathbf{M}_{CV}$ là mặt nạ Canny. Toán tử hợp (Union) được thực hiện, theo sau là phép toán Dilation (Giãn nở hình thái học) với phần tử cấu trúc (Structuring Element) B :

$$\mathbf{M}_{hybrid} = (\mathbf{M}_{DL} \cup \mathbf{M}_{CV}) \oplus B = \bigcup_{b \in B} (\mathbf{M}_{DL} \cup \mathbf{M}_{CV})_b \quad (3.8)$$

Thuật toán `repair_wide_v1` được nhóm định nghĩa nhằm điều chỉnh động kích thước của B phụ thuộc vào độ dày của vết nứt, đảm bảo mặt nạ bao phủ toàn bộ hiện tượng halo (quầng sáng hồng) để không để lại đường viền đen sau khi Inpainting.

3.5. Module 2: Inpainting sử dụng Pretrained LaMa Backend thông qua Subprocess Wrapper



Hình 3.4: Kiến trúc luồng xử lý và đánh giá Loss theo thiết kế Trục Kép (Twin-Bus) của Module 2.

Mô hình LaMa (Large Mask Inpainting) với kiến trúc Tích chập Fourier Nhanh (FFC) được sử dụng để tối đa hóa receptive field, đặc biệt hiệu quả cho các vết nứt dài hoặc vùng mất dữ liệu lớn. Nhờ

chuyển một nửa số kênh đặc trưng sang miền tần số, LaMa có thể khai thác thông tin toàn cục từ xa, vượt qua giới hạn của convolution cục bộ.

Do LaMa yêu cầu một môi trường dependency phức tạp (PyTorch version cũ, CUDA specific libraries) dễ xung đột với các thư viện khác trong pipeline chính, việc tích hợp trực tiếp vào mã nguồn là bất khả thi về mặt kỹ thuật phần mềm. Hệ thống giải quyết "bottleneck" này bằng kiến trúc **Subprocess Wrapper**. Pipeline chính (Python) sẽ thiết lập một tiến trình con (subprocess), gọi giao diện dòng lệnh (CLI) của môi trường ảo (virtual environment) chứa LaMa:


Listing 3.1: Cơ chế Subprocess Wrapper gọi LaMa Backend

```
def run_lama_inpainting(img_path, mask_path, out_dir):
    lama_env = "/opt/lama_env/bin/python"
    cmd = [lama_env, "predict.py",
           f"--image={img_path}", f"--mask={mask_path}",
           f"--outdir={out_dir}"]
    subprocess.run(cmd, check=True)
```

Cách tiếp cận này không chỉ đảm bảo an toàn bộ nhớ (memory isolation) mà còn cho phép phân tán hệ thống (microservices) trong tương lai. Trong phạm vi đề án, LaMa được sử dụng ở dạng **pretrained** (không fine-tune trên dữ liệu ảnh cũ). Do đó, chất lượng inpainting phụ thuộc mạnh vào mask đầu vào và khả năng tổng quát của mô hình. Để đảm bảo nhất quán, ảnh và mask trước khi gọi LaMa đều được resize về cùng kích thước 512×512 và lưu dưới dạng file tạm thời. Pipeline cũng tích hợp cơ chế bắt lỗi (try/except) để ghi nhật ký khi tiến trình con thất bại, tránh ảnh hưởng đến các module khác.

3.6. Module 3: Phục hồi màu ảnh sau LaMa (Color Restoration)

Sau khi qua inpainting, ảnh có thể vẫn còn các suy thoái màu sắc như ám vàng, phai màu, tông sepia, mất cân bằng kênh hoặc artifact do nén. Module phục hồi màu được thiết kế chuyên biệt để xử lý các vấn đề này một cách “bảo thủ có kiểm soát”, không làm thay đổi nội dung cấu trúc đã được phục hồi bởi LaMa.



Hình 3.5: Luồng xử lý của Module 3 — Phục hồi màu sau LaMa.

3.6.1. Chiến lược dữ liệu và tiền xử lý

Vì ảnh cũ thật không có ground truth, module sử dụng dữ liệu paired synthetic. Ảnh sạch từ DIV2K/FFHQ được suy giảm bằng profile faded_color_v2, giữ lại chroma có ích (không làm ảnh hoàn toàn grayscale). Phân phối các subprofile: Identity 5%, Mild yellow 15%, Faded old 45%, Moderate sepia 25%, Hard degradation 10%. Mỗi mẫu có target là ảnh sạch gốc, đảm bảo bài toán phục hồi màu chứ không phải colorization.

Cả training và inference đều áp dụng **OpenCV conservative preprocessing** nhất quán: ảnh RGB → fastNlMeansDenoisingColored (h=3, hColor=3) → chuyển sang Lab → CLAHE chỉ trên kênh L (clipLimit=1.35, grid 8×8) → chuyển về RGB → Gaussian blur nhẹ (sigmaX=1.0) → unsharp masking (1.12×image − 0.12×blurred). Các bước này giảm nhiễu màu, tăng tương phản cục bộ mà không ảnh hưởng đến sắc độ.

3.6.2. Kiến trúc ColorRestorationUNet và dự đoán residual trong không gian Lab

Mô hình sử dụng U-Net encoder-decoder, GroupNorm (batch size nhỏ), LeakyReLU. Đầu vào RGB được chuẩn hóa về $[-1, 1]$, đầu ra là ba residual r_L, r_a, r_b bị chặn trong $[-1, 1]$ nhờ hàm tanh. Ảnh input được chuyển sang không gian Lab, sau đó cập nhật:

$$L_{\text{out}} = \text{clamp}(L_{\text{in}} + 15 r_L, 0, 100) \quad (3.9)$$

$$a_{\text{out}} = \text{clamp}(a_{\text{in}} + 40 r_a, -128, 127) \quad (3.10)$$

$$b_{\text{out}} = \text{clamp}(b_{\text{in}} + 40 r_b, -128, 127) \quad (3.11)$$

Giới hạn 15 cho luminance và 40 cho chroma được chọn để tránh thay đổi quá mạnh.

3.6.3. Hàm mất mát tổng hợp

Loss kết hợp giữa không gian RGB, Lab, SSIM, histogram và identity:

$$\mathcal{L}_{\text{total}} = 0.5\mathcal{L}_{\text{RGB}} + 0.5\mathcal{L}_L + 1.0\mathcal{L}_{ab} + 0.2\mathcal{L}_{\text{SSIM}} + 0.1\mathcal{L}_{\text{hist}} + 0.2\mathcal{L}_{\text{identity}} \quad (3.12)$$

Trong đó: $\mathcal{L}_{\text{hist}}$ là Earth Mover's Distance giữa histogram của kênh a, b (64 bins, lấy tối đa 4096 pixel), $\mathcal{L}_{\text{identity}}$ chỉ tác động lên identity samples để giữ nguyên ảnh tốt. Loss được huấn luyện với AdamW, lr=2e-4, CosineAnnealingLR, batch size 8, 50 epoch. Checkpoint tốt nhất được chọn theo validation loss (epoch 42).

3.6.4. Inference trên ảnh full-resolution (Tiled inference)

Để xử lý ảnh kích thước bất kỳ (thường lớn hơn crop 256×256), module sử dụng overlapping tiles: ảnh được chia thành các tile 256×256, overlap 64 pixel, chạy model theo batch (batch size 4), sau đó ghép bằng cửa sổ Hann (trọng số giảm dần về biên, minimum weight 0.05). Phương pháp này tránh mất chi tiết và seam.

3.6.5. Kiểm soát suy luận (Inference Control)

Raw output của model có thể gây oversaturation hoặc thay đổi luminance quá mức. Do đó, pipeline áp dụng:

- **Lab protected blending:** Kết hợp ảnh quality (sau preprocessing) và ảnh model trong không gian Lab:

$$L_{\text{ctrl}} = L_{\text{qual}} + s_L(L_{\text{model}} - L_{\text{qual}}), \quad ab_{\text{ctrl}} = ab_{\text{qual}} + s_{ab}(ab_{\text{model}} - ab_{\text{qual}})$$

với $s_L = 0.35$, $s_{ab} = 0.65$ (chấp nhận thay đổi màu nhiều hơn luminance).

- **Automatic chroma gate:** Dựa trên mean chroma của ảnh quality, tự động giảm cường độ chroma khi ảnh gần grayscale: mean chroma $< 4 \rightarrow$ strength 0.20; $< 8 \rightarrow$ 0.40; $< 12 \rightarrow$ 0.60; $\geq 12 \rightarrow$ 0.70.

3.6.6. Color Correction Matrix (CCM) toàn cục

Sau inference control, module ước lượng diagonal CCM trong không gian linear RGB dựa trên gray-world assumption. Các pixel tham chiếu được chọn từ vùng mid-tone (luminance percentile 35-95) và


$\text{saturation} \leq 0.55$. Từ mean RGB (μ_R, μ_G, μ_B) của các pixel đó, tính gain:

$$n = \sqrt[3]{\mu_R \mu_G \mu_B}, \quad g_c = n / \mu_c$$

Sau đó giới hạn gain trong $[1-d, 1+d]$ với $d = 0.15$, và blend với identity: $g_c^{\text{applied}} = 1 + 0.45 (g_c^{\text{limited}} - 1)$. Ma trận CCM cuối chỉ có các hệ số đường chéo, giúp hiệu chỉnh toàn cục nhẹ nhàng, tránh thay đổi hue chủ đạo. Tỷ lệ clipping được ghi vào metadata để giám sát.

Module 3 được huấn luyện độc lập, tích hợp vào pipeline như một bước bắt buộc (không phải tùy chọn) sau LaMa, đảm bảo ảnh đầu ra có màu sắc trung thực và tự nhiên hơn.

3.7. Module 4: Phục hồi khuôn mặt tùy chọn với CodeFormer



Hình 3.6: Luồng xử lý của Module 4: phát hiện khuôn mặt bằng RetinaFace, nếu có thì kích hoạt CodeFormer (VQVAE codebook + Transformer) để phục hồi chi tiết vùng mặt, sau đó blend lại ảnh gốc. Module này là tùy chọn, có cảnh báo rủi ro hallucination.

Sau khi qua các module segmentation, inpainting (LaMa) và phục hồi màu, một số ảnh cũ có chứa khuôn mặt vẫn có thể bị mờ, thiếu chi tiết hoặc biến dạng nhẹ do vùng nứt/xước che phủ. Tuy nhiên, cần phân biệt rõ:

- **LaMa (Module 2)** được thiết kế để lấp đầy các cấu trúc tuần hoàn như vân giấy, nếp áo, kết cấu nền. Nó **không có tiên nghiệm (prior) về giải phẫu học** của khuôn mặt người. Việc áp dụng inpainting trực tiếp lên vùng mặt dễ gây ra hiện tượng méo mó cấu trúc, mất cân đối hoặc tạo ra các chi tiết bất thường (facial distortion).
- **CodeFormer (Module 4)** là mô hình chuyên biệt cho blind face restoration, sử dụng codebook

và Transformer để tái tạo cấu trúc khuôn mặt dựa trên các thành phần giải phẫu đã học từ tập dữ liệu lớn (FFHQ). Module này chỉ được kích hoạt **tùy chọn** và có điều kiện.

3.7.1. Luồng hoạt động có điều khiển bằng cổng (Conditional Gate)

Hệ thống tích hợp CodeFormer như một module **optional, dependency-gated**. Luồng xử lý (Hình 3.6) gồm các bước:

1. **Phát hiện khuôn mặt với RetinaFace:** Ảnh đầu ra của Module 3 (sau inpainting và phục hồi màu) được đưa qua bộ phát hiện khuôn mặt RetinaFace. RetinaFace trả về các bounding box kèm độ tin cậy. Ngưỡng mặc định là 0.5.
2. **Kiểm tra điều kiện kích hoạt:** Module 4 chỉ được chạy nếu **(a)** có ít nhất một khuôn mặt được phát hiện, **(b)** người dùng đã bật tùy chọn (ví dụ qua CLI `-use_codeformer` hoặc checkbox trong UI). Nếu không thỏa, pipeline bỏ qua module này và giữ nguyên ảnh.
3. **Trích xuất và lượng tử hóa đặc trưng:** Vùng khuôn mặt được cắt ra, đưa qua encoder để trích xuất đặc trưng tiềm ẩn z_h . CodeFormer sử dụng một từ điển mã (codebook) $\mathcal{C} = \{c_k \in \mathbb{R}^d\}_{k=1}^K$ đã được học trước từ tập dữ liệu khuôn mặt chất lượng cao (FFHQ). Quá trình lượng tử hóa (quantization) tìm vector mã gần nhất:

$$z_q = \arg \min_{c_k \in \mathcal{C}} \|z_h - c_k\|_2$$

4. **Tái tạo bằng Transformer:** Một mạng Transformer nhận chuỗi các token rời rạc từ codebook và dự đoán chuỗi token phù hợp cho vùng mặt bị khuyết, sau đó giải mã thành ảnh khuôn mặt sắc nét. Cơ chế này chuyển bài toán từ "sinh pixel từ pixel" thành "tra cứu và ghép nối các thành phần giải phẫu chuẩn", giúp tránh các dạng méo hình thường thấy ở inpainting thông thường.
5. **Kiểm soát độ trung thực (fidelity weight w):** CodeFormer cho phép điều chỉnh tham số w để cân bằng giữa độ sắc nét và độ trung thực so với ảnh gốc. Trong hệ thống, w được thiết lập mặc định là 0.7 (ưu tiên giữ lại danh tính gốc). Giá trị w càng cao, ảnh càng bám sát đầu vào, ít thay đổi; w càng thấp, ảnh càng sắc nét nhưng có nguy cơ sinh ra chi tiết mới (hallucination).
6. **Blending:** Vùng mặt đã được phục hồi được ghép lại vào ảnh gốc. Một phép làm mờ Gaussian nhẹ (sigma=1) được áp dụng ở biên vùng ghép để tránh đường viền cứng.

3.7.2. Rủi ro hallucination và giới hạn diễn giải

CodeFormer là mô hình sinh, do đó tiềm ẩn rủi ro **hallucination** (tự bịa ra các chi tiết không có trong ảnh gốc như nếp nhăn, hình dáng mắt, mũi, miệng không chính xác). Đối với ảnh lịch sử hoặc ảnh gia đình, sự thay đổi này có thể làm sai lệch danh tính nhân vật, ảnh hưởng đến giá trị tư liệu.

Trong phạm vi đồ án, **nhóm chưa đánh giá bảo toàn danh tính** bằng các metric chuyên biệt như ArcFace similarity hay CosFace. Vì vậy:

- Module CodeFormer được thiết kế ở chế độ **tùy chọn (optional)** và mặc định **tắt**.
- Người dùng muốn kích hoạt cần hiểu rõ rủi ro và chỉ nên dùng cho các ảnh không yêu cầu bảo tồn nghiêm ngặt danh tính.
- Trong báo cáo, mọi kết quả liên quan đến CodeFormer đều được trình bày kèm theo cảnh báo rõ ràng, không được coi là bằng chứng phục hồi chính xác danh tính.

3.7.3. Cấu hình vận hành

Bảng 3.1: Tham số vận hành của Module 4

Tham số	Giá trị mặc định	Diễn giải
Detection threshold	0.5	Ngưỡng tin cậy của RetinaFace để kích hoạt.
Fidelity weight w	0.7	Cân bằng giữa trung thực (cao) và làm đẹp (thấp).
Blending sigma	1.0	Làm mờ biên vùng ghép để tránh seam.
GPU	Tự động (nếu có)	Fallback về CPU nếu không đủ VRAM.

Module này không tham gia vào quá trình đánh giá chất lượng cốt lõi (segmentation benchmark, restoration check) mà chỉ được coi là bước *hậu kỳ tăng cường trực quan*. Mọi kết luận về khả năng phục hồi khuôn mặt trong báo cáo đều kèm theo giới hạn đã nêu.

Chương 4

Thiết lập thực nghiệm và triển khai hệ thống

4.1. Mở đầu

Chương 3 đã mô tả hệ thống phục hồi ảnh cũ ở cấp độ phương pháp: các module, kiến trúc segmenter (hai option R013/R014), cơ chế mask refinement, inpainting bằng LaMa, phục hồi màu (Module 3) và face restoration tùy chọn (Module 4). Chương 4 chuyển từ câu hỏi “hệ thống gồm những thành phần nào” sang câu hỏi “các thành phần đó được huấn luyện, cấu hình, quản lý và vận hành trong điều kiện cụ thể nào”. Đây là bước trung gian bắt buộc trước khi trình bày kết quả ở Chương 5, bởi vì một kết quả thực nghiệm chỉ có ý nghĩa khi người đọc biết rõ dữ liệu, split, tiền xử lý, siêu tham số và chính sách quản lý artifact.

Trọng tâm của chương này là **xác lập các điều kiện để việc so sánh giữa các cấu hình (R013 vs R014) là công bằng và có thể tái lập**, đồng thời mô tả chi tiết thiết lập cho Module 3 (phục hồi màu) vốn được huấn luyện độc lập với bộ dữ liệu synthetic riêng. Chương cũng làm rõ ranh giới giữa các loại đánh giá: benchmark segmentation, restoration check, qualitative demo và smoke/regression test.


4.2. Mục tiêu của thiết lập thực nghiệm

Thiết lập thực nghiệm phục vụ ba mục tiêu chính:

1. **Tạo điều kiện huấn luyện mô hình phân đoạn trong bối cảnh dữ liệu ảnh thật có nhãn hạn chế.** Vì ảnh cũ thật hầu như không có ảnh sạch tương ứng, nhóm phải kết hợp dữ liệu tổng hợp (có ground truth) và dữ liệu ảnh thật đã được gán nhãn thủ công. Cách tổ chức này phản ánh sự đánh đổi giữa khả năng kiểm soát của synthetic data và mức độ gần thực tế của real-domain data.
2. **Đảm bảo các cấu hình segmenter được so sánh trong điều kiện công bằng.** R013 và R014 khác nhau ở kiến trúc encoder, tiền xử lý, và chính sách threshold/dilation. Mọi so sánh về chỉ số segmentation (IoU, F1) phải dựa trên **cùng tập dữ liệu, cùng split, cùng quy ước tính metric**. Nếu không kiểm soát split, sự khác biệt có thể đến từ độ khó của mẫu test thay

vì từ thay đổi kiến trúc.

3. **Biến pipeline nghiên cứu thành hệ thống có thể chạy lại và kiểm thử được.** Điều này bao gồm tổ chức checkpoint, manifest, external dependencies, readiness checker, CLI và giao diện demo. Các thành phần này không thay thế kết quả học sâu, nhưng giúp kết quả có thể được kiểm tra và trình bày ổn định trong điều kiện đồ án.



Hình 4.1: Luồng thiết lập thực nghiệm: từ dữ liệu, split cố định, huấn luyện R013/R014, đánh giá segmentation, sau đó kiểm tra downstream (mask refinement, inpainting, phục hồi màu) và quản lý artifact.

4.3. Môi trường thực nghiệm và hệ quả thiết kế

Các thử nghiệm được xây dựng trên hệ sinh thái Python và PyTorch, với các thành phần chính được tóm tắt trong Bảng 4.1.

Bảng 4.1: Môi trường thực nghiệm và hệ quả đối với phương pháp

Thành phần	Thiết lập	Ý nghĩa đối với thiết kế
Framework học sâu	PyTorch (phiên bản 2.x)	Dùng cho huấn luyện và suy luận segmenter R013/R014, cũng như module màu.
Xử lý ảnh	OpenCV, NumPy, PIL	Hỗ trợ resize, mask processing, morphology, preprocessing cho module màu.
Huấn luyện segmenter	Kaggle GPU T4 (16GB VRAM)	Đủ để huấn luyện R013 và R014, nhưng không đủ để fine-tune LaMa.
Huấn luyện module màu	Local RTX 3060 12GB hoặc T4	Đủ cho U-Net nhỏ (7.7M tham số) với batch size 8.
Debug và demo	Local workstation (Ubuntu 22.04, i7, 32GB RAM, RTX 3060)	Dùng cho đóng gói repo, UI, readiness checker và smoke tests.
Backend ngoài	LaMa (môi trường riêng, PyTorch 1.12), CodeFormer (conda env)	Giảm xung đột dependency, subprocess wrapper cho LaMa.

Giới hạn tài nguyên ảnh hưởng trực tiếp đến chiến lược: nhóm tập trung GPU vào segmenter và module màu, còn LaMa được tích hợp dưới dạng pretrained backend. Quyết định này giúp khai thác năng lực inpainting của mô hình lớn mà không biến phần huấn luyện LaMa thành trọng tâm vượt quá tài nguyên.

4.4. Dữ liệu sử dụng và vai trò của từng miền dữ liệu

4.4.1. Tổng quan các nhóm dữ liệu

Dữ liệu trong đề tài được tổ chức theo vai trò (Bảng 4.2). Ngoài dữ liệu cho segmentation (synthetic + real), còn có dữ liệu riêng cho module phục hồi màu.

Bảng 4.2: Các nhóm dữ liệu và vai trò thực nghiệm

Nhóm dữ liệu	Vai trò chính	Ground truth	Giới hạn khi diễn giải
DIV2K HR / ảnh sạch	Nền ảnh sạch để sinh ảnh hỏng (crack và màu).	Có ảnh sạch.	Không đại diện texture giấy và scan artifacts.
Crack Bank / RGBA	Mẫu crack/scratch có alpha mask.	Có mask.	Độ đa dạng phụ thuộc tập thu thập.
Synthetic degraded pairs (crack)	Pretrain segmenter R006–R009.	Có mask, có ảnh sạch.	Domain gap so với ảnh thật.
Synthetic faded pairs (màu)	Huấn luyện ColorRestorationUNet.	Có ảnh sạch.	Domain gap về điều kiện ảnh cũ thật.
Real old photos	Kiểm tra định tính	Thường không có.	Chỉ dùng định tính.
r013_finetune_set	Fine-tune/evaluate segmenter R013/R014.	Có image-mask (118 cặp).	Quy mô nhỏ (test 17).

4.4.2. Dữ liệu cho segmentation: r013_finetune_set và split cố định

Tập r013_finetune_set là tập chính cho đánh giá segmenter. Sau khi lọc 120 cặp ban đầu, loại hai mẫu size mismatch, còn 118 cặp hợp lệ. Split cố định: 83 train, 18 validation, 17 test. Split file dataset_index_fixed.csv dùng chung cho R013 và R014 (Bảng 4.3).

Bảng 4.3: Split cố định của `r013_finetune_set`

Mục	Giá trị	Ý nghĩa
Số cặp ban đầu	120	Tập thu thập trước lọc.
Mẫu bị loại	real_0099, real_0112	Không khớp kích thước.
Số cặp hợp lệ	118	Dùng cho huấn luyện/đánh giá segmenter.
Train	83	Fine-tune.
Validation	18	Chọn checkpoint.
Test	17	Held-out split.

4.4.3. Dữ liệu cho module phục hồi màu (Color Restoration)

Module màu sử dụng chiến lược paired synthetic. Ảnh sạch từ DIV2K và FFHQ được suy giảm bằng profile `faded_color_v2` (chi tiết trong Chương 3). Các nguồn ảnh được chia theo source ID trước khi sinh biến thể: train 80%, val 10%, test 10%. Mỗi source sinh 3 train variants, 1 eval variant. Kích thước crop khi sinh là 320×320 , training crop ngẫu nhiên 256×256 . Target là ảnh sạch gốc (không suy giảm). Identity samples (5%) giúp model học hành vi pass-through.

4.5. Tiền xử lý và chuẩn hóa

4.5.1. Cho segmentation: R013 và R014

Cả hai cùng resize ảnh về 512×512 (`cv2.INTER_LINEAR`). Normalization khác nhau: - R013: chia 255.0 (đưa về $[0, 1]$). - R014: ImageNet normalization $(\mathbf{x}/255.0 - \boldsymbol{\mu})/\boldsymbol{\sigma}$ với $\boldsymbol{\mu} = [0.485, 0.456, 0.406]$, $\boldsymbol{\sigma} = [0.229, 0.224, 0.225]$.

Khi inference, R014 dùng `pretrained=False` và nạp checkpoint cục bộ (không tải từ Internet).

4.5.2. Cho module màu: OpenCV conservative preprocessing

Cả training và inference đều áp dụng pipeline: RGB $\rightarrow$ `fastNlMeansDenoisingColored` (`h=3`) $\rightarrow$ RGB $\rightarrow$ Lab $\rightarrow$ CLAHE trên L (`clipLimit=1.35`) $\rightarrow$ Lab $\rightarrow$ RGB $\rightarrow$ Gaussian blur (`sigma=1.0`) $\rightarrow$ unsharp masking ($1.12 \times \text{image} - 0.12 \times \text{blurred}$). Đầu ra sau đó được chuẩn hóa về $[-1, 1]$ và đưa vào model.

4.6. Thiết lập huấn luyện

4.6.1. Segmenter: R013 và R014

Cả hai đều huấn luyện trên tập `r013_finetune_set` với split cố định, dùng BCE + Dice loss, Adam `lr=1e-4`, batch size 8, 40 epoch, early stopping. R013 threshold mặc định 0.50, R014 threshold 0.30

(sau sweep). Bảng 4.4 tóm tắt vai trò.

Bảng 4.4: Vai trò thực nghiệm của R013 và R014

Cấu hình	Thiết lập chính	Vai trò trong luận văn
R013	Custom lightweight Attention U-Net; BCE+Dice; /255.0; threshold 0.50.	Stable fallback/default.
R014	ResNet-34 encoder + U-Net decoder; ImageNet norm; threshold 0.30; dilation 3x3.	Architecture ablation và recommended demo option.

4.6.2. Module phục hồi màu (ColorRestorationUNet)

- Kiến trúc: U-Net, GroupNorm, LeakyReLU, đầu ra tanh (3 residual).
- Loss tổng hợp:

$$\mathcal{L}_{total} = 0.5\mathcal{L}_{RGB} + 0.5\mathcal{L}_L + 1.0\mathcal{L}_{ab} + 0.2\mathcal{L}_{SSIM} + 0.1\mathcal{L}_{hist} + 0.2\mathcal{L}_{identity}$$

- Optimizer: AdamW, lr=2e-4, weight decay 1e-4, CosineAnnealingLR.
- Batch size 8, 50 epoch, early stopping patience 10, chọn checkpoint theo validation total loss.
- Huấn luyện trên dữ liệu synthetic faded_color_v2 (DIV2K + FFHQ). Checkpoint tốt nhất tại epoch 42 với val loss 0.083595.
- Checkpoint SHA256: a32ff2975967d5b2cd81634c5f4ef026bb184892b10de38a70e37961f9927c91.

4.7. Quản lý checkpoint, artifact và khả năng tái lập

Repository tách source code (theo dõi Git) và payload lớn (checkpoint, dataset, output) bị ignore. File `manifest.yaml` lưu đường dẫn, SHA256 và nguồn tải. Script `verify_artifacts.py` kiểm tra tính toàn vẹn. Ví dụ checkpoint R014:

```
- name: "checkpoints/segmenter/seg-unet-resnet34-r014-s42/best_val_iou.pth"
  sha256: "e1d84ced2e3aac6fd89bbe48bd6149cc445cc7308b03887ac3f66de2352924c2"
```

Module màu checkpoint tương tự.

4.8. Triển khai runtime: CLI, UI, readiness checker và dependency ngoài

4.8.1. Command-line interface (CLI)

Cú pháp mẫu:

```
python run_pipeline.py --input old.jpg --segmenter r014 --threshold 0.30 --dilation 3 --use_lama
```

4.8.2. Gradio UI

Cho phép tải ảnh, chọn segmenter, điều chỉnh threshold/dilation, bật/tắt LaMa, CodeFormer, hiển thị các bước trung gian.

4.8.3. Readiness checker

Kiểm tra checkpoint, external paths (LaMa, CodeFormer), CUDA, SHA256.

4.8.4. Subprocess wrapper cho LaMa

```
def run_lama(img_path, mask_path, out_dir, lama_env):
    cmd = [lama_env, "predict.py", f"--image={img_path}", f"--mask={mask_path}", f"--outdir={out_dir}"]
    subprocess.run(cmd, check=True, timeout=120)
    return cv2.imread(os.path.join(out_dir, os.path.basename(img_path)))
```

4.9. Kiểm thử hồi quy và phạm vi diễn giải

Các loại kiểm thử được phân biệt rõ (Bảng 4.5). Đặc biệt, Demo3 regression test (golden case) ghi nhận Mask IoU > 0.999 và PSNR > 66 dB so với golden, nhưng chỉ để xác nhận code không bị gãy, không phải benchmark chất lượng.

Bảng 4.5: Các loại kiểm thử và phạm vi diễn giải

Loại kiểm thử	Ví dụ	Được kết luận	Không được kết luận
Syntax/build check	python -m compileall pass	Code không lỗi cú pháp	Chất lượng mô hình tốt
Artifact check	SHA256 match	Đúng checkpoint cục bộ	Checkpoint đã commit
Pipeline smoke test	R013/R014 chạy không lỗi	Luồng runtime không gãy	Benchmark chất lượng
Demo3 regression	Mask IoU 0.99977; PSNR 66.64 dB	Code nhất quán với golden	Hệ thống đạt chất lượng cao trên test set
Held-out evaluation	R013/R014 trên 17 test samples	Kết quả segmentation trong split đã nêu	Khái quát cho mọi ảnh cũ

4.10. Kết luận chương

Chương 4 đã trình bày toàn bộ thiết lập thực nghiệm cho cả module segmentation (R013/R014) và module phục hồi màu, bao gồm môi trường, dữ liệu, split, tiền xử lý, siêu tham số huấn luyện, quản lý artifact và triển khai runtime. Các điểm chính:

- Tập `r013_finetune_set` 118 cặp, split cố định 83/18/17, dùng chung cho R013 và R014.
- Dữ liệu synthetic cho màu: DIV2K/FFHQ, profile `faded_color_v2`, split theo source ID, crop 320→256.
- Preprocessing: segmentation (R013: /255.0; R014: ImageNet norm); màu (OpenCV conservative).
- Huấn luyện segmenter với BCE+Dice, 40 epoch; module màu với loss tổng hợp, 50 epoch, best epoch 42.
- Quản lý artifact bằng manifest + SHA256, không commit binary.
- CLI, UI, readiness checker, subprocess wrapper cho LaMa.
- Phân biệt rõ regression test, smoke test, benchmark.

Với nền tảng này, Chương 5 sẽ trình bày các kết quả định lượng, định tính và phân tích lỗi theo từng module.

Chương 5

KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN

5.1. Mở đầu

Chương 4 đã xác lập điều kiện thực nghiệm chung: dữ liệu, split, tiền xử lý, checkpoint. Chương 5 trình bày kết quả đánh giá lần lượt cho hai module chính của pipeline:

- **Module 1 – Phát hiện và lấp vết nứt/scratch:** baseline end-to-end, segmentation (R006–R014), mask refinement, restoration check, threshold/dilation sweep.
- **Module 3 – Phục hồi màu sau inpainting:** ColorRestorationUNet dự đoán Lab residual, inference control, diagonal CCM, đánh giá bằng PSNR/SSIM/DeltaE.

Mục tiêu của chương không chỉ liệt kê chỉ số, mà giải thích mỗi kết quả đã dẫn đến quyết định thiết kế nào trong từng module. Các kết quả được phân tách theo bản chất đánh giá để tránh diễn giải sai phạm vi.

5.2. Mục tiêu và phạm vi đọc kết quả

Chương 5 trả lời các câu hỏi thực nghiệm theo từng module.

5.2.1. Câu hỏi cho Module 1

1. Mô hình U-Net end-to-end ban đầu có đủ tốt cho ảnh thật không?
2. Synthetic pretraining có giúp segmenter nhận biết crack trên ảnh thật không?
3. Real-domain fine-tuning và thay đổi target mask cải thiện segmenter ra sao?
4. R013 đóng vai trò stable fallback trên cơ sở nào?
5. R014 (ResNet-34) cải thiện segmentation thế nào khi so sánh cùng split?
6. Vì sao cải thiện IoU/F1 chưa chắc cải thiện ảnh inpainting cuối cùng?

7. Threshold/dilation sweep giải quyết vấn đề mask morphology ra sao?

5.2.2. Câu hỏi cho Module 3

1. Mô hình dự đoán Lab residual có đạt chất lượng phục hồi màu tốt hơn hiệu chỉnh toàn cục không?
2. Cơ chế điều chỉnh theo vùng (spatially-varying) thể hiện qua đâu?
3. Các tham số inference control (blending, chroma gate, CCM) đóng góp thế nào vào độ an toàn?

Bảng 5.1: Phạm vi sử dụng các nhóm kết quả

Nhóm kết quả	Chỉ số / bằng chứng	Ý nghĩa đúng	Giới hạn diễn giải
Segmentation benchmark	IoU, F1 trên split có nhãn	Đánh giá độ đúng mask R013/R014	Không kết luận chất lượng ảnh inpainting
Restoration check	PSNR, MAE, masked MAE trên 15 mẫu	Ảnh hưởng mask morphology đến LaMa	Quy mô nhỏ, dùng ablation/policy
Color benchmark (ước tính)	PSNR, SSIM, DeltaE	Sai lệch pixel, cấu trúc, màu sắc	Chưa có benchmark chính thức
Qualitative demo	Before, mask, output	Minh họa hiện tượng theo module	Không thay thế đánh giá định lượng
Smoke/regression test	Demo3 IoU/PSNR so với golden output	Xác nhận code sau refactor không gây	Không dùng làm bằng chứng chất lượng

5.3. Module 1 – Phân đoạn và phục hồi vết nứt

5.3.1. Kết quả baseline end-to-end

Model A với L1 loss

Model A (U-Net, L1 loss) đạt PSNR 23.3540 dB và SSIM 0.7662 trên tập synthetic DIV2K. Đánh giá định tính trên ảnh thật cho thấy output mờ, bệt màu, mất texture nền, không lấp triệt để vết nứt lớn.

Các biến thể loss

Model B/B2 (L1+SSIM) cho PSNR 19.10 dB, SSIM 0.676. Model C2 (L1+masked L1) thể hiện ý tưởng đúng nhưng không giải quyết tổng quát hóa.

Kết luận

U-Net nguyên khối không đủ ổn định cho mixed degradation. Đây là bằng chứng chuyển sang pipeline mô-đun.

Bảng 5.2: Kết quả baseline end-to-end (Module 1)


Mô hình	Kiến trúc / loss	Metric ghi nhận	Diễn giải
Model A	U-Net, L1	PSNR 23.3540; SSIM 0.7662 trên synthetic	Baseline tốt nhất nhưng ảnh thật mờ, bệt.
Model B/B2	U-Net, L1+SSIM	PSNR 19.10; SSIM 0.676	SSIM không cải thiện.
Model C2	U-Net, L1+masked L1	Không dùng làm kết quả chính	Ý tưởng tốt nhưng chưa thay thế định vị bằng mask.

5.3.2. Synthetic pretraining và bằng chứng domain gap


Chuỗi R006–R009 trên dữ liệu synthetic cho thấy Val IoU tăng từ 0.3852 lên 0.4171, Val F1 từ 0.5249 lên 0.5595. Chuyển từ BCE+Dice sang BCE+Tversky (R008) cải thiện recall.

Phát hiện domain gap: R009 đạt Val IoU 0.4171 trên synthetic, nhưng Real Test IoU chỉ 0.0022 – bằng chứng định lượng mạnh nhất.


Lỗi định tính: False positive trên nếp áo, tóc, cạnh vật thể; false negative trên crack mờ, mảnh.



Hình 5.1: Validation IoU trên synthetic của R006–R009.



Hình 5.2: Best validation IoU giữa các run synthetic.




Hình 5.3: Domain gap: R009 đạt IoU 0.4171 trên synthetic nhưng Real Test IoU chỉ 0.0022.

Bảng 5.3: Kết quả synthetic pretraining và domain gap

Run	Thiết lập chính	Val IoU	Val F1	Diễn giải
R006	BCE+Dice, 50 epoch	0.3852	0.5249	Điểm khởi đầu.
R007	Augmentation mạnh	0.3912	0.5257	Tăng nhẹ.
R008	BCE+Tversky	0.4064	0.5492	Loss phù hợp mất cân bằng lớp.
R009	BCE+Tversky, 60 epoch	0.4171	0.5595	Validation tốt, real-domain thất bại.
R009 real check	Đánh giá trên ảnh thật	0.0022	–	Domain gap rất lớn.

5.3.3. Real-domain fine-tuning R010–R013

- **R010** (thin mask): Real Test IoU 0.2927, F1 0.4528 – vượt domain gap, nhưng mask quá mảnh cho LaMa.
- **R011** (repair mask v1): Test IoU 0.4478, F1 0.6186 – target mask phù hợp hơn cho inpainting.
- **R012** (15 manual masks): Test IoU 0.2846, F1 0.4430 – small-data ablation thất bại.
- **R013** (operational): Test IoU 0.366412, F1 0.536312 – stable fallback.



Hình 5.4: Tiến trình real-domain fine-tuning: Real Test IoU và F1 từ R010 đến R013.


Bảng 5.4: Chuỗi real-domain fine-tuning R010–R013

Run	Dữ liệu / mask	Metric ghi nhận	Quyết định
R010	Real thin mask, fine-tune từ R009	Real Test IoU 0.2927; F1 0.4528	Vượt domain gap, mask mạnh.
R011	Repair mask v1, fine-tune từ R010	Test IoU 0.4478; F1 0.6186	Repair mask phù hợp hơn.
R012	15 manual masks, fine-tune từ R011	Test IoU 0.2846; F1 0.4430	Small-data ablation thất bại.
R013	Fixed/valid pairs (118)	Test IoU 0.366412; F1 0.536312	Stable fallback.

5.3.4. So sánh segmentation cuối: R013 (Attention U-Net) vs R014 (ResNet-34)

Cùng split 83 train, 18 val, 17 test trên tập `r013_finetune_set`.

- R013: threshold 0.50 → Test IoU 0.366412, F1 0.536312.
- R014: threshold 0.30 → Test IoU 0.450604, F1 0.621264.
- Delta: +0.084192 IoU, +0.084952 F1.



Hình 5.5: So sánh định tính hoặc metric giữa R013 và R014.

Minh họa định tính



Hình 5.6: R013: Mask -> Lama



Hình 5.7: R014: Mask -> Lama

Bảng 5.5: So sánh R013 và R014 trên cùng split

Cấu hình	Kiến trúc	Thresh.	Val IoU	Val F1	Test IoU	Test F1
R013	Attention U-Net (custom)	0.50	0.390467	0.561658	0.366412	0.536312
R014	ResNet-34 + U-Net + Att. Gate	0.30	0.406005	0.577530	0.450604	0.621264
Delta	R014 – R013	–	+0.015538	+0.015872	+0.084192	+0.084952

Diễn giải: R014 cải thiện segmentation nhờ encoder mạnh, nhưng chưa chắc cho inpainting tốt hơn. R013 vẫn là fallback.

5.3.5. Restoration check: ảnh hưởng của mask morphology

Trên 15 mẫu có ground truth:

- R013 (threshold 0.50, no dilation): mean PSNR 16.69 dB, mean MAE 30.31.
- R014 no-dilation (threshold 0.30): mean PSNR 16.59 dB, mean MAE 30.56.


Mask R014 bám sát lỗi crack (tốt cho IoU) nhưng quá hẹp cho LaMa, dẫn đến inpainting không tốt hơn.

Bảng 5.6: Restoration check 15 mẫu (R013 vs R014 no-dilation)

Cấu hình	Mean PSNR (dB)	Mean MAE	Diễn giải
R013 (threshold 0.50)	16.69	30.31	Stable fallback, mask thô phù hợp hơn.
R014 no-dilation (threshold 0.30)	16.59	30.56	Segmentation tốt nhưng mask quá khít.

5.3.6. Threshold/dilation sweep cho R014

Chính sách được chọn: **threshold = 0.30**, **dilation 1 lần kernel 3×3** . Kết quả: masked MAE cải thiện khoảng -1.04 so với R013. Repair mask sau hậu xử lý tốt hơn raw mask.



Hình 5.8: Ảnh hưởng của threshold và dilation lên mask và kết quả inpainting.

Bảng 5.7: Chính sách threshold/dilation cho R014

Thành phần	Giá trị	Vai trò	Rủi ro nếu sai
Threshold	0.30	Chuyển prob map thành binary mask.	Quá cao $\rightarrow$ bỏ sót crack mờ; quá thấp $\rightarrow$ FP.
Dilation	1 lần, kernel 3×3	Mở rộng nhẹ bao phủ halo.	Quá rộng $\rightarrow$ xóa nhầm chi tiết; quá hẹp $\rightarrow$ sẹo.
Tác động	masked MAE cải thiện ≈ -1.04	Repair mask hữu ích hơn raw mask.	Không thay thế benchmark lớn.

5.4. Module 3 – Phục hồi màu sau inpainting

Module 3 xử lý ảnh RGB sau LaMa qua các bước:

1. OpenCV conservative: NLMeans ($h=3$), CLAHE trên kênh L ($\text{clipLimit}=1.35$), unsharp nhẹ.
2. ColorRestorationUNet dự đoán Lab residual (r_L, r_a, r_b), giới hạn L15, ab40.
3. Lab protected blending: $s_L = 0.35, s_{ab} = 0.65$ và chroma gate (giảm strength khi mean chroma thấp).
4. Diagonal CCM trong linear RGB: gain $\pm 15\%$, strength 45%.

Dữ liệu huấn luyện: paired synthetic với profile `faded_color_v2` (loại ảnh gần grayscale, target là ảnh sạch gốc). Đánh giá ước tính trên 50 ảnh synthetic + 15 ảnh thật có ground truth nhân tạo.

5.4.1. Kết quả định lượng ước tính

Bảng 5.8: Chỉ số chất lượng ước tính của mô hình phục hồi màu (Module 3)

Chỉ số	Giá trị ước tính	Ý nghĩa
PSNR $\uparrow$	24.126 dB	Sai số tái tạo pixel thấp.
SSIM $\uparrow$	0.8724	Bảo toàn cấu trúc và chi tiết.
Delta E CIEDE2000 $\downarrow$	6.7315	Sai lệch màu cảm nhận ở mức chấp nhận được.
LPIPS-VGG $\downarrow$	Chưa đánh giá	Cần bổ sung.


So với hiệu chỉnh toàn cục (gray-world CCM, histogram matching) đạt PSNR 21 dB, SSIM 0.83, DeltaE 9–10, module mới vượt trội nhờ khả năng điều chỉnh theo vùng.

5.4.2. Khả năng hiệu chỉnh theo vùng (spatially-varying)

Vì mô hình dự đoán residual cho từng pixel:

- Vùng da được điều chỉnh khác với nền $\rightarrow$ tránh làm sai màu da khi nền bị ám vàng.
- Vùng bạc màu (mất chroma nhiều) được tăng cường mạnh hơn.
- Vùng trung tính (tường, giấy) thay đổi ít, giữ bối cảnh.
- Duy trì biên màu giữa các vật thể, giảm oversaturation.

Cơ chế blending và chroma gate (giảm strength khi mean chroma <12 , <8 , <4) tăng độ an toàn, tránh ảo màu trên ảnh gần grayscale.



Hình 5.9: Chuyển màu ảnh qua các giai đoạn thử nghiệm.

5.4.3. Hạn chế của kết quả ước tính

- Chưa có benchmark chính thức theo split source ID.


- Chưa đo LPIPS – thiếu đánh giá khoảng cách cảm nhận.
- Các tham số blending và chroma gate heuristic, chưa tối ưu end-to-end.
- Domain gap giữa synthetic và ảnh thật vẫn còn.
- CCM diagonal chưa xử lý cross-channel cast.

Tuy vậy, kết quả đủ khẳng định hướng thiết kế (Lab residual + control) hiệu quả và an toàn hơn hiệu chỉnh toàn cục.

5.5. Đánh giá định tính tổng hợp và smoke test


5.5.1. Đánh giá định tính

- **Module 1:** Ca thành công (mask đúng, inpainting tự nhiên); ca thất bại (FP trên tóc/nếp áo, FN crack mờ, sọc do mask hẹp, xóa nhầm do mask rộng).
- **Module 3:** Ảnh đầu vào ám vàng/phai màu → sau module, da trở lại tự nhiên, nền giữ tông cũ hài hòa.




Hình 5.10: Tiến trình pipeline từ ảnh cũ → mask → inpainting → phục hồi màu.


- **FULL PIPELINE:** Hình bắt nét ổn có thể định hình và xóa nét cũng như hồi phục màu sâu sắc.



Hình 5.11: Ví dụ minh họa pipeline đầy đủ: (a) Ảnh gốc, (b) Mask overlay, (c) LaMa inpainting, (d) Phục hồi màu, (e) CodeFormer (tùy chọn).



Hình 5.12: Một ví dụ khác của pipeline.



Hình 5.13: Ví dụ thứ ba.

5.5.2. Demo3 regression test

Demo3 golden case: Mask IoU 0.99977, Restored PSNR 66.6367 dB so với golden output – xác nhận code sau refactor không bị gãy. **Không dùng** để khẳng định chất lượng phục hồi trên toàn bộ ảnh thật.

Bảng 5.9: Phân biệt đánh giá định tính và kiểm thử hồi quy

Loại bằng chứng	Ví dụ	Ý nghĩa	Cách đọc
Qualitative demo	Before / mask / output	Minh họa hành vi pipeline	Phân tích hiện tượng, không kết luận thống kê
Demo3 regression	Mask IoU 0.99977; PSNR 66.6367 dB	Xác nhận code không gây	Dùng cho software readiness
Benchmark segmentation	R013/R014 trên 17 test images	So sánh năng lực mask	Kết luận về segmentation
Restoration check	15 mẫu R013/R014/no-dilation/mask morphology	Kiểm tra ảnh hưởng mask morphology	Kết luận về policy nhỏ

5.6. Phân tích lỗi theo module

Bảng 5.10: Failure modes theo từng module (Module 1 và Module 3)

Module	Dấu hiệu lỗi	Nguyên nhân	Hướng xử lý
Segmenter (M1)	FP trên tóc/nếp áo, FN crack mờ	Domain gap, foreground nhỏ	Real data, backbone mạnh hơn
Mask refinement (M1)	Mask hẹp gây sẹo; rộng xóa nhầm	Trade-off coverage	Adaptive dilation, UI sửa mask
LaMa (M1)	Inpainting không tự nhiên vùng lớn	Pretrained, chưa domain-adapt	Fine-tune hoặc backend khác
Color (M3)	Ảo màu trên ảnh gần grayscale, overshoot	Heuristic control, domain gap	Benchmark, học adaptive blending, CCM 3x3

5.7. Thảo luận tổng hợp

5.7.1. Module 1

- Baseline end-to-end (Model A) chỉ đạt metric trên synthetic, không tổng quát.
- Synthetic pretraining có domain gap lớn (R009).
- Real-domain fine-tuning (R010–R013) và repair mask (R011) là giải pháp hiệu quả.
- R014 cải thiện segmentation (+0.084 IoU) nhưng mask cần dilation phù hợp.
- Mask morphology (threshold/dilation) là nút thắt nối segmentation và inpainting.

5.7.2. Module 3

- Huấn luyện trên synthetic có thể đạt kết quả tốt nếu có cơ chế control an toàn.
- Lab residual + blending theo vùng vượt trội so với hiệu chỉnh toàn cục.
- Các tham số heuristic (sL, sab, chroma gate) giảm rủi ro khi triển khai thực tế.

5.7.3. Bài học phương pháp luận

- Không đánh đồng metric giữa các tầng: IoU/F1 cho mask, PSNR/MAE cho inpainting, PSNR/SSIM/DeltaE cho màu.
- Domain gap synthetic–real là rào cản lớn, cần real-data fine-tuning hoặc cơ chế an toàn.
- Cải thiện từng module độc lập nhưng phải xét ảnh hưởng downstream.

5.8. Kết luận chương

Chương 5 đã trình bày kết quả thực nghiệm tách biệt cho Module 1 và Module 3.

Module 1:

- Model A (end-to-end) đạt PSNR 23.35 trên synthetic nhưng ảnh thật mờ, bệt.
- Synthetic pretraining (R006–R009) cải thiện Val IoU lên 0.4171 nhưng Real Test IoU chỉ 0.0022.
- Real-domain fine-tuning: R013 đạt Test IoU 0.3664, F1 0.5363.
- R014 cải thiện segmentation (+0.084 IoU) so với R013.
- Restoration check: R014 no-dilation PSNR 16.59 vs R013 16.69.
- Chính sách threshold 0.30 + dilation 3×3 cải thiện masked MAE ≈ -1.04 .

Module 3:

- Mô hình Lab residual đạt ước tính PSNR 24.126 dB, SSIM 0.8724, DeltaE 6.73.
- Điều chỉnh màu theo vùng vượt trội so với hiệu chỉnh toàn cục.
- Các cơ chế control heuristic, cần benchmark chính thức và tối ưu thêm.

Các kết quả củng cố thiết kế mô-đun: Module 1 cần dữ liệu real và chú trọng mask morphology; Module 3 hoạt động tốt trên synthetic với cơ chế an toàn. Những giới hạn còn lại (dữ liệu nhỏ, thiếu benchmark, chưa fine-tune LaMa, LPIPS chưa đo) sẽ được phân tích ở Chương 6.

Chương 6

HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN

6.1. Mở đầu

Các chương trước đã trình bày quá trình hình thành pipeline, thiết kế hệ thống, thiết lập thực nghiệm và kết quả đánh giá. Chương 6 không nhằm phủ nhận các kết quả đã đạt, mà làm rõ phạm vi hiệu lực của chúng. Với một hệ thống phục hồi ảnh cũ dựa trên nhiều module, chất lượng cuối không chỉ phụ thuộc vào mô hình học sâu, mà còn phụ thuộc vào dữ liệu, mặt nạ, backend inpainting, cách đánh giá và điều kiện triển khai.

Vì vậy, các hạn chế trong chương này được phân tích theo từng nhóm nguyên nhân: dữ liệu, mô hình phân đoạn, mask refinement, inpainting, ****phục hồi màu****, đánh giá thực nghiệm, triển khai phần mềm và phạm vi bài toán. Cách tiếp cận này giúp chỉ ra phần nào của hệ thống cần được cải thiện trước, phần nào thuộc giới hạn dữ liệu, phần nào là ràng buộc tài nguyên, và phần nào cần được xem như hướng phát triển dài hạn.

6.2. Tổng quan các nhóm hạn chế của hệ thống

Pipeline cuối của đề tài gồm nhiều tầng xử lý: dữ liệu ảnh cũ, segmenter R013 hoặc R014, mask refinement, LaMa inpainting, ****module phục hồi màu (Lab residual + inference control + CCM)**** và CodeFormer tùy chọn. Một lỗi ở tầng đầu có thể lan sang các tầng sau. Chẳng hạn, nếu dữ liệu gán nhãn chưa đủ đa dạng, segmenter dễ bỏ sót crack mảnh; nếu mask quá hẹp, LaMa có thể để lại sọc viền; nếu mask quá rộng, vùng ảnh còn đúng có thể bị xóa và sinh lại; nếu module phục hồi màu nhận input bị ám màu quá nặng, output có thể overshoot hoặc tạo màu không tự nhiên. Do đó, hạn chế của hệ thống cần được nhìn như một chuỗi phụ thuộc.

Bảng 6.1: Tổng hợp các nhóm hạn chế chính của hệ thống (bao gồm color restoration)

Nhóm hạn chế	Dấu hiệu trong dự án	Ảnh hưởng chính	Hướng xử lý tổng quát
Dữ liệu	Tập ảnh thật có nhãn còn nhỏ (118 cặp); test split 17 ảnh; synthetic vẫn có domain gap.	Mô hình khó tổng quát sang ảnh thật đa dạng.	Mở rộng real annotated dataset và chuẩn hóa quy trình gán nhãn.
Segmenter	R013 ổn định nhưng encoder nhẹ; R014 tăng IoU/F1 nhưng cần mask policy phù hợp.	False positive/false negative vẫn xuất hiện ở ảnh khó.	Kiến trúc đa tỉ lệ, encoder mạnh hơn, active learning.
Mask refinement	Mask hẹp để lại sọc; mask rộng xóa nhầm chi tiết.	Tác động trực tiếp đến LaMa và ảnh đầu ra.	Adaptive dilation, confidence-aware refinement, UI sửa mask.
LaMa	Dùng pretrained backend, không fine-tune trong phạm vi đồ án.	Giới hạn ở vùng khuyết lớn hoặc cấu trúc phức tạp.	Domain adaptation hoặc thử backend inpainting khác.
Phục hồi màu	Synthetic training, heuristic control, gray-world CCM; thiếu benchmark.	Ảo màu, overshoot, không hiệu quả với ảnh gần grayscale.	Real paired data, adaptive control, học CCM hoặc confidence-based fusion.
Đánh giá	Restoration check 15 mẫu; Demo3 chỉ là regression test.	Chưa đủ để kết luận chất lượng phục hồi quy mô lớn.	Benchmark rộng hơn, no-reference metrics, user study.
Triển khai	External dependencies, checkpoint local, subprocess wrapper.	Cài đặt phức tạp, có overhead khi suy luận.	Docker, artifact automation, ONNX/TensorRT.

6.3. Hạn chế về dữ liệu

6.3.1. Quy mô real annotated data nhỏ

Hạn chế quan trọng nhất của đề tài là dữ liệu ảnh thật có nhãn còn nhỏ. Tập `r013_finetune_set` ban đầu có 120 cặp ảnh-mask, nhưng sau khi rà soát chỉ còn 118 cặp hợp lệ do hai mẫu bị lỗi không khớp kích thước. Split cuối gồm 83 ảnh train, 18 ảnh validation và 17 ảnh test. Quy mô này đủ để kiểm chứng hướng tiếp cận trong phạm vi đồ án, nhưng chưa đủ để đại diện cho toàn bộ phổ ảnh cũ thật, vốn có sự khác biệt lớn về chất liệu giấy, điều kiện scan, độ phai màu, vết ố, texture nền và kiểu vết nứt.

6.3.2. Domain gap giữa synthetic và real

Chương 5 đã cho thấy dữ liệu synthetic dù được xây dựng có kiểm soát vẫn không triệt tiêu domain gap. R009 đạt IoU tương đối tốt trên synthetic validation, nhưng gần như sụp đổ khi kiểm tra trên ảnh thật (Real Test IoU 0.0022). Điều này cho thấy các đặc trưng của vết nứt tổng hợp không đủ bao phủ các biến thể xuất hiện trong ảnh cũ thực tế. Các cấu trúc như tóc, nếp áo, cạnh vật thể, vết ố hoặc texture giấy có thể tạo ra tín hiệu tương tự crack và làm tăng false positive; ngược lại, crack mảnh hoặc phai màu dễ bị bỏ sót.

6.3.3. masks_fixed không phải repair-wide dataset

Một điểm cần phân biệt là `masks_fixed` chỉ có vai trò chuẩn hóa lỗi nhị phân và kích thước. Nó không phải một tập wide-mask được thiết kế riêng cho inpainting. Điều này khiến bài toán target mask vẫn còn mở: mask phục vụ segmentation và mask phục vụ repair/inpainting có mục tiêu khác nhau. Trong tương lai, nếu có quy trình gán nhãn tốt hơn, nhóm cần tách rõ ground-truth segmentation mask và repair-oriented mask để huấn luyện và đánh giá phù hợp hơn.

Bảng 6.2: Hạn chế dữ liệu và hướng khắc phục

Hạn chế	Bảng chứng/biểu hiện	Ảnh hưởng	Hướng phát triển
Quy mô real data nhỏ	118 cặp hợp lệ; test split 17 ảnh	Kết quả có ý nghĩa trong phạm vi test split nhưng chưa đại diện cho mọi ảnh cũ.	Mở rộng tập ảnh thật có nhãn, đa dạng hóa nguồn ảnh và mức độ hư hỏng.
Synthetic domain gap	R009 giảm mạnh từ synthetic validation sang real-domain test	Pretraining không đủ để triển khai trực tiếp trên ảnh thật.	Kết hợp synthetic pretraining với real fine-tuning, domain randomization, active learning.
Thiếu ground truth sạch cho ảnh thật	Ảnh lịch sử/gia đình không có ảnh gốc	PSNR/SSIM khó dùng cho ảnh thật.	Dùng no-reference IQA, user study và benchmark synthetic có ground truth.
<code>masks_fixed</code> không phải repair-wide dataset	Chỉ sửa lỗi binary/size	Target mask cho segmentation chưa chắc phù hợp cho inpainting.	Thiết kế bộ nhãn repair mask riêng hoặc UI chỉnh mask bán tự động.

6.4. Hạn chế về mô hình phân đoạn

6.4.1. R013: encoder nhẹ, năng lực biểu diễn hạn chế

R013 được giữ làm stable fallback/default vì ổn định, nhẹ và phù hợp với pipeline hiện tại. Tuy nhiên, R013 là custom lightweight Attention U-Net với encoder gọn, nên năng lực biểu diễn vẫn có giới hạn. Trong các ảnh có nền phức tạp hoặc crack có tương phản thấp, mô hình có thể bỏ sót vùng hư hỏng mảnh. Ngược lại, các cạnh vật thể hoặc texture nền có hình dạng giống crack có thể bị dự đoán nhầm.

6.4.2. R014: cải thiện segmentation nhưng chưa hoàn hảo

R014 khắc phục một phần giới hạn này bằng ResNet-34 encoder và cho kết quả IoU/F1 tốt hơn R013 trên cùng split. Tuy nhiên, kết quả Chương 5 cũng cho thấy cải thiện segmentation không đồng nghĩa tự động cải thiện ảnh phục hồi cuối cùng. R014 có xu hướng tạo mask bám sát lõi vết nứt hơn; điều này có lợi cho metric segmentation nhưng có thể thiếu vùng bao lề cần thiết cho LaMa. Do đó, hạn chế của segmenter không thể chỉ được giải bằng việc tăng backbone; cần xét cả mục tiêu downstream của mask.

6.4.3. Hướng phát triển cho segmenter

Các hướng phát triển hợp lý gồm: (i) kiến trúc đa tỉ lệ để giữ tốt hơn crack mảnh; (ii) attention hoặc transformer-based segmentation để khai thác ngữ cảnh rộng; (iii) loss điều chỉnh theo false negative/false positive; (iv) học chủ động để ưu tiên gán nhãn những ảnh mà mô hình còn bất định. Tuy nhiên, mọi cải tiến kiến trúc nên đi kèm mở rộng dữ liệu thật có nhãn; nếu dữ liệu vẫn hẹp, mô hình lớn hơn có thể chỉ làm tăng nguy cơ overfit.

6.5. Hạn chế về mask refinement và hybrid mask

6.5.1. Trade-off giữa coverage và chính xác

Mask refinement là điểm nối giữa segmentation và inpainting, cũng là nơi xuất hiện trade-off rõ nhất của hệ thống. Nếu mask quá hẹp, LaMa chỉ lấp phần lõi crack và có thể để lại halo, bóng đổ hoặc sọc viền. Nếu mask quá rộng, LaMa có thể xóa nhầm chi tiết thật như tóc, mắt, chữ viết hoặc texture nền còn đúng. Vì vậy, mask phù hợp cho LaMa không nhất thiết là mask có IoU cao nhất theo nhãn segmentation.

6.5.2. Hybrid mask và policy tĩnh

Hybrid mask giúp bổ sung tín hiệu từ xử lý ảnh truyền thống, chẳng hạn các biên mảnh mà DL mask có thể bỏ sót. Tuy nhiên, các kỹ thuật như Canny, CLAHE hoặc blackhat cũng dễ phản ứng với nếp áo, cạnh vật thể và nhiễu giấy, làm tăng false positive. Chính sách R014 threshold 0.30 kết hợp

dilation 3x3 cho thấy hiệu quả trong 15-sample restoration check, nhưng đây vẫn là policy tĩnh. Nó chưa bảo đảm tối ưu cho mọi ảnh, mọi độ rộng crack và mọi mức texture nền.

6.5.3. Hướng phát triển

Một hướng phát triển có tính thực tế cao là thêm UI chỉnh sửa mask trước khi inpainting. So với việc huấn luyện lại toàn bộ backend, human-in-the-loop mask editing có thể cải thiện ngay các ca khó: người dùng xóa false positive rõ ràng hoặc tô thêm crack bị bỏ sót. Hướng này đặc biệt phù hợp với ảnh gia đình hoặc ảnh lịch sử, nơi người dùng chấp nhận can thiệp thủ công để đổi lấy kết quả đáng tin cậy hơn. Ngoài ra, có thể phát triển adaptive dilation dựa trên độ rộng crack hoặc confidence-aware fusion thay vì union cố định.

Bảng 6.3: Trade-off trong mask refinement và hướng phát triển

Tình huống	Lợi ích	Rủi ro	Hướng phát triển
Mask hẹp	Giữ nhiều chi tiết gốc, ít xóa nhầm.	LaMa thiếu vùng halo, output có thể còn sọc.	Dilation nhẹ hoặc adaptive dilation theo độ rộng crack.
Mask rộng	Bao phủ đủ crack, bóng đổ và vùng chuyển tiếp.	Có thể xóa nhầm chi tiết thật.	Giới hạn dilation bằng confidence map hoặc object-aware constraints.
Hybrid DL + CV	Tăng khả năng bắt crack mảnh.	CV mask dễ tạo false positive trên texture/cạnh.	Confidence-aware fusion thay vì union cố định.
Policy tĩnh 3x3	Đơn giản, dễ tái lập và đã cải thiện masked MAE trong check nhỏ.	Không thích ứng với ảnh quá nhiều texture hoặc crack quá lớn.	Tối ưu mask theo từng ảnh hoặc cho phép người dùng chỉnh mask.

6.6. Hạn chế về LaMa inpainting backend

6.6.1. Pretrained, chưa domain-adapt

LaMa đóng vai trò quan trọng vì giúp hệ thống có khả năng lấp vùng hư hỏng mà không cần nhóm tự huấn luyện một mô hình inpainting lớn từ đầu. Tuy nhiên, trong phạm vi đồ án, LaMa được dùng như pretrained/local backend, không được fine-tune trên dữ liệu ảnh cũ riêng. Quyết định này phù hợp với tài nguyên hiện có, nhưng đồng thời đặt ra giới hạn: LaMa không được tối ưu chuyên biệt cho texture giấy cũ, vết nứt lịch sử hoặc các vùng hư hỏng rất đặc thù của ảnh scan.

6.6.2. Phụ thuộc mạnh vào mask

Kết quả thực nghiệm cho thấy LaMa phụ thuộc mạnh vào mask đầu vào. Khi mask đúng và vùng hỏng nhỏ đến trung bình, backend inpainting có thể tạo nội dung hợp lý về mặt thị giác. Nhưng nếu

mask bỏ sót, vết nứt vẫn còn; nếu mask quá rộng, LaMa có thể sinh lại vùng không cần sửa. Với các vùng mất dữ liệu lớn, mất một phần khuôn mặt hoặc cấu trúc hình học phức tạp, output có thể plausible nhưng không bảo đảm đúng với nội dung lịch sử ban đầu.

6.6.3. Hướng phát triển

Trong tương lai, nhóm có thể xem xét fine-tune hoặc domain-adapt backend inpainting nếu có dữ liệu và GPU đủ mạnh. Một hướng khác là thử các backend diffusion-based inpainting (ví dụ Stable Diffusion with inpainting) hoặc mô hình inpainting mới hơn, nhưng cần đánh giá cẩn thận vì mô hình sinh mạnh hơn cũng có thể tăng rủi ro hallucination. Với ảnh cũ mang giá trị lịch sử, mục tiêu không chỉ là làm ảnh đẹp hơn mà còn phải kiểm soát mức độ thay đổi nội dung.

6.7. Hạn chế về CodeFormer và phục hồi khuôn mặt

CodeFormer được tích hợp như module tùy chọn, không phải đường đánh giá chính của đề tài. Vai trò hợp lý của nó là tăng cường cảm nhận thị giác cho vùng mặt trong một số ảnh, đặc biệt khi ảnh gốc bị mờ hoặc mất chi tiết. Tuy nhiên, vì CodeFormer là mô hình sinh ảnh, nó có thể tạo ra chi tiết khuôn mặt trông hợp lý nhưng không chắc đúng với người trong ảnh gốc (hallucination). Giới hạn này đặc biệt quan trọng đối với ảnh lịch sử hoặc ảnh gia đình. Trong phạm vi đồ án, nhóm chưa đo identity preservation bằng các metric như ArcFace hoặc CosFace. Vì vậy, CodeFormer nên tiếp tục được giữ ở trạng thái optional/dependency-gated, kèm khả năng bật/tắt và cảnh báo rõ về rủi ro sinh chi tiết mới. Hướng phát triển phù hợp là bổ sung cơ chế fidelity-adjustable blending, cho phép cân bằng giữa độ sắc nét và độ trung thực, cùng với đánh giá định lượng identity nếu module này được xem là thành phần quan trọng.

6.8. Hạn chế của module phục hồi màu (Color Restoration)

Module phục hồi màu, dù đạt được các kết quả ước tính PSNR 24.126 dB, SSIM 0.8724 và DeltaE 6.73, vẫn tồn tại nhiều hạn chế cần được nhận diện rõ.

6.8.1. Domain gap giữa synthetic training và ảnh thật

Mô hình ColorRestorationUNet được huấn luyện chủ yếu trên dữ liệu synthetic với profile faded_color_v2. Dữ liệu này mô phỏng suy giảm màu bằng các phép biến đổi toàn cục (gamma, cast, sepia, v.v.) và nhiễu nhẹ. Tuy nhiên, ảnh cũ thực tế có thể chứa các quá trình hóa học phức tạp, scan artifacts, vùng màu biến đổi phi tuyến, texture giấy, hoặc lỗi từ LaMa không xuất hiện trong training. Do đó, mô hình có thể hoạt động kém hơn trên các ảnh thật có suy giảm màu nằm ngoài phân phối synthetic. Bằng chứng gián tiếp là các giá trị strength blending (sL=0.35, sab=0.65) và chroma gate được đưa ra như các cơ chế an toàn, chứng tỏ raw model chưa đủ tin cậy khi triển khai thực tế.

6.8.2. Không phải mô hình colorization

Profile V2 cố ý loại bỏ các ảnh nguồn có mean chroma quá thấp (<4.0) và chỉ giữ lại các ảnh có màu sắc nhất định. Điều này có nghĩa là mô hình không được thiết kế để colorize ảnh đen trắng hoàn toàn. Nếu đưa vào một ảnh gần grayscale, mô hình có thể tạo ra màu ảo (hallucinated color) hoặc phản ứng không ổn định. Chroma gate (giảm strength khi mean chroma <12) là một biện pháp bảo vệ, nhưng không phải giải pháp triệt để.

6.8.3. Inference control là heuristic, không được tối ưu end-to-end

Các tham số $sL=0.35$, $sab=0.65$ và các ngưỡng chroma (4,8,12) được xác định qua ablation trên một tập nhỏ ảnh thật, không phải kết quả của một quá trình tối ưu tham số có hệ thống. Chúng phản ánh nhu cầu an toàn hơn là tối ưu metric. Mặc dù hiệu quả trong nhiều trường hợp, không thể đảm bảo chúng tối ưu cho mọi loại ảnh đầu vào. Tương tự, diagonal CCM với gain $\pm 15\%$ và strength 45% là lựa chọn bảo thủ dựa trên gray-world assumption, không phải lúc nào cũng đúng (ví dụ ảnh có màu chủ đạo có chủ ý như hoàng hôn hoặc cỏ xanh).

6.8.4. Chưa có benchmark chính thức trên tập test độc lập

Các kết quả định lượng (PSNR, SSIM, DeltaE) mới chỉ là ước tính trên tập con (50 synthetic + 15 ảnh thật có ground truth nhân tạo). Chưa có benchmark hoàn chỉnh trên tập test được chia theo source ID (như split 80/10/10 từ các ảnh sạch). Do đó, các chỉ số này chưa thể khẳng định chất lượng tổng quát của module. Cũng chưa có so sánh công bằng với các phương pháp phục hồi màu khác (ví dụ: retinex-based, white balance, color constancy, hoặc các deep learning models khác) trên cùng dữ liệu.

6.8.5. Chưa đánh giá LPIPS và các metric cảm nhận khác

LPIPS-VGG chưa được đo, mặc dù đây là metric quan trọng để đánh giá khoảng cách cảm nhận giữa ảnh phục hồi và ground truth. Ngoài ra, chưa có đánh giá trên ảnh thật không ground truth bằng các no-reference metrics (NIQE, PIQE, BRISQUE) hoặc user study. Do đó, tuyên bố về chất lượng cảm nhận hiện dựa chủ yếu vào một vài demo định tính.

6.8.6. Hạn chế về mặt kỹ thuật trong implementation

Một số hạn chế kỹ thuật cũng cần được ghi nhận: việc chuyển đổi Lab và clamp residual có thể gây sai số do precision nếu không được xử lý cẩn thận (dùng float32 trong các bước nhảy cảm). Tiled inference với overlap 64 và Hann window làm tăng thời gian xử lý, chưa được tối ưu cho CPU hay GPU. CCM hiện chỉ dùng diagonal matrix, chưa khai thác được khả năng hiệu chỉnh cross-channel của ma trận đầy đủ 3×3 . Metadata lưu trữ (json) chưa có cơ chế versioning để truy vết thay đổi pipeline.

Bảng 6.4: Hạn chế cụ thể của module phục hồi màu và hướng khắc phục

Hạn chế	Biểu hiện / bằng chứng	Ảnh hưởng	Hướng phát triển
Domain gap synthetic-real	Training chỉ trên faded_color_v2; real ảnh có suy giảm phức tạp hơn.	Model có thể không ổn định trên ảnh thật ngoài phân phối.	Thu thập paired real data; fine-tune; domain randomization mạnh hơn.
Không phải colorization	Loại ảnh chroma thấp khỏi training; chroma gate giảm strength.	Ảnh gần grayscale có thể bị ảo màu hoặc không được cải thiện.	Tách bài toán: phục hồi màu vs. colorization; nếu cần colorization thì thiết kế lại.
Inference control heuristic	sL=0.35, sab=0.65, chroma gate ngưỡng 4/8/12.	Chưa tối ưu cho mọi ảnh; có thể quá bảo thủ hoặc chưa đủ mạnh.	Học tham số blending từ dữ liệu; confidence-based adaptive blending.
Thiếu benchmark chính thức	Chỉ ước tính trên tập con; chưa split source ID.	Khó so sánh công bằng với phương pháp khác.	Xây dựng benchmark chuẩn: synthetic test set theo source ID, real-image review set.
Chưa đo LPIPS, chưa user study	LPIPS chưa có; demo định tính là chính.	Thiếu bằng chứng về chất lượng cảm nhận.	Bổ sung LPIPS, thực hiện user study với MOS.
CCM diagonal, gray-world assumption	Gain $\pm 15\%$, strength 45%.	Không sửa được cross-channel cast; sai với ảnh có màu chủ đạo.	Thử CCM 3x3 có regularization; confidence-based selection; học CCM từ dữ liệu.

6.8.7. Hướng phát triển cho module phục hồi màu

Từ các hạn chế trên, các hướng phát triển ưu tiên cho module màu bao gồm:

- Bổ sung benchmark chuẩn:** Đánh giá trên tập synthetic test theo đúng split source ID, báo cáo PSNR, SSIM, LPIPS, DeltaE, Mean Chroma Error. Với ảnh thật, xây dựng tập review với ground truth nhân tạo hoặc dùng no-reference IQA + user study.
- Cải thiện dữ liệu training:** Thu thập thêm các cặp ảnh thật suy giảm và ảnh sạch (nếu có thể). Mở rộng synthetic degradation profile để bao phủ nhiều dạng hư hỏng màu thực tế hơn (uneven fading, local color cast, artifact do scan).
- Tối ưu inference control:** Thay vì tham số cố định, có thể học blending strength từ dữ liệu hoặc dùng confidence map (ví dụ dự đoán độ tin cậy của từng pixel residual). Chroma gate có thể được thay bằng adaptive weighting dựa trên mean chroma và phương sai cục bộ.
- Nâng cao CCM:** Thử nghiệm CCM đầy đủ 3x3 với regularization (ví dụ gần với ma trận đơn

vị) để tránh overfitting. Hoặc ước lượng gain theo từng vùng (spatially-varying CCM) dựa trên segmentation của ảnh (da, trời, cây, v.v.).

5. **Tích hợp đánh giá định lượng thường xuyên:** Trong quá trình phát triển, cần có CI pipeline chạy benchmark màu trên tập con để phát hiện regression sớm.

6.9. Hạn chế về đánh giá thực nghiệm

6.9.1. Phạm vi còn hẹp

Đánh giá trong đồ án đã phân biệt segmentation benchmark, restoration check, qualitative demo và smoke/regression test. Tuy nhiên, phạm vi của từng nhóm đánh giá vẫn còn hạn chế. Segmentation benchmark chủ yếu dựa trên test split 17 ảnh có nhãn. Restoration check mới được thực hiện trên 15 mẫu để phân tích tác động của threshold/dilation. Các demo định tính giúp quan sát trực quan nhưng không thay thế benchmark quy mô lớn.

6.9.2. Demo3 không phải benchmark

Một điểm dễ gây hiểu nhầm là Demo3 regression test. Các chỉ số như mask IoU gần 1 hoặc PSNR cao trong ca này chỉ có ý nghĩa kiểm tra output hiện tại có khớp golden output hay không sau refactor. Nó thuộc nhóm kiểm thử kỹ nghệ phần mềm, không phải thước đo chất lượng phục hồi trên tập ảnh đa dạng. Vì vậy, các kết luận chất lượng mô hình phải dựa trên split đánh giá hoặc protocol restoration rõ ràng, không dựa trên một golden case nội bộ.

6.9.3. Hướng phát triển đánh giá

Trong tương lai, cần xây dựng giao thức đánh giá phục hồi rộng hơn. Với synthetic data có ground truth, có thể đo PSNR, SSIM, LPIPS hoặc FID theo thiết lập rõ ràng. Với ảnh thật thiếu ground truth, có thể bổ sung no-reference IQA như BRISQUE, NIQE, hoặc đánh giá người dùng theo Mean Opinion Score (MOS). Quan trọng hơn, failure case cần được thống kê theo taxonomy: lỗi do segmenter, do refinement, do LaMa, do color restoration hay do CodeFormer. Khi đó, kết quả không chỉ nói hệ thống tốt hay xấu, mà chỉ rõ cần cải thiện module nào.

Bảng 6.5: Giới hạn của các nhóm đánh giá hiện tại và hướng phát triển

Nhóm đánh giá	Ý nghĩa phù hợp	Giới hạn	Hướng phát triển
Segmentation benchmark	Đo IoU/F1 trên test split có nhãn.	Test set nhỏ (17 ảnh); chỉ đánh giá mask, không đo ảnh cuối.	Mở rộng test split, phân tích theo nhóm lỗi.
Restoration check 15 mẫu	Kiểm tra tác động mask policy lên inpainting.	Quy mô nhỏ, chưa phải benchmark toàn hệ thống.	Tăng số mẫu, chia mức độ hư hỏng, đo thêm metric cảm nhận.
Qualitative demo	Minh họa before/mask/output và failure case.	Dễ cảm tính nếu không gắn với module gây lỗi.	Chuẩn hóa bộ demo và chú thích lỗi theo taxonomy.
Smoke test	Kiểm tra code không gãy sau refactor.	Không phản ánh chất lượng mô hình trên dữ liệu thật.	Giữ riêng trong nhóm software QA.
Color benchmark (chưa có)	Đo chất lượng phục hồi màu.	Chưa có protocol chuẩn, chỉ ước tính.	Xây dựng benchmark trên synthetic test split và real-image set.

6.10. Hạn chế về triển khai và phần mềm

Ở góc độ triển khai, hệ thống vẫn phụ thuộc vào nhiều artifact và external dependency. Các checkpoint .pth, LaMa weights, CodeFormer weights và dataset lớn không được commit trực tiếp vào Git, mà được quản lý local/external qua manifest hoặc `external_paths.yaml`. Cách tổ chức này giúp repo nhẹ và sạch, nhưng làm quá trình cài đặt phụ thuộc vào việc người chạy đã đặt đúng artifact hay chưa. LaMa được gọi qua subprocess wrapper để tránh xung đột dependency và giảm rủi ro OOM, nhưng tạo overhead khi suy luận và khiến môi trường chạy phức tạp hơn. Hướng phát triển phù hợp là đóng gói môi trường chạy bằng Docker hoặc notebook Kaggle/Colab có hướng dẫn artifact rõ ràng. Nếu hướng đến triển khai thực tế, nhóm có thể nghiên cứu ONNX/TensorRT hoặc tối ưu batch processing. Tuy nhiên, tối ưu tốc độ nên đứng sau việc củng cố dữ liệu, mask và đánh giá.

6.11. Hạn chế về phạm vi bài toán

Hệ thống hiện tập trung vào crack/scratch restoration, tức phát hiện và lấp các vùng hư hỏng có cấu trúc hẹp đến trung bình. Nó chưa phải pipeline phục hồi ảnh cũ toàn diện. Các vấn đề như phai màu toàn ảnh, nhiễu hạt nặng, blur do scan, super-resolution, colorization hoặc phục hồi vùng mất dữ liệu rất lớn chưa được xử lý như kết quả chính. Điều này không làm giảm giá trị của đồ án, vì việc tập trung vào crack/scratch giúp nhóm đi sâu vào segmentation, mask morphology và inpainting. Tuy nhiên, nếu muốn mở rộng thành hệ thống phục hồi ảnh cũ hoàn chỉnh hơn, cần bổ sung các module theo thứ tự hợp lý: denoising/deblurring, colorization, super-resolution, và workflow tương tác. Đối với màu sắc, module hiện tại chỉ xử lý suy giảm màu nhẹ đến trung bình; nếu ảnh bị phai màu nặng

hoặc mất hoàn toàn thông tin chroma, cần một hướng tiếp cận khác (ví dụ colorization dựa trên reference hoặc generative).

6.12. Hướng phát triển ưu tiên

Từ các hạn chế trên, lộ trình phát triển nên được ưu tiên theo mức độ tác động và tính khả thi. Hướng quan trọng nhất không phải lập tức thay toàn bộ kiến trúc bằng mô hình lớn hơn, mà là mở rộng dữ liệu thật có nhãn và cải thiện mask refinement. Đây là hai điểm tác động trực tiếp đến cả segmenter lẫn LaMa, đồng thời khả thi hơn so với fine-tune backend inpainting lớn. Đối với module màu, cần ưu tiên xây dựng benchmark và thu thập dữ liệu real paired trước khi thay đổi kiến trúc phức tạp.

Bảng 6.6: Lộ trình phát triển ưu tiên sau đồ án (tích hợp cả color restoration)

Ưu tiên	Hướng phát triển	Vì sao quan trọng	Yêu cầu chính	Tác động kỳ vọng
1	Mở rộng real annotated dataset (segmentation)	Giảm domain gap, tăng độ tin cậy của benchmark.	Nguồn ảnh thật, quy trình gán mask, kiểm soát chất lượng nhãn.	Segmenter tổng quát tốt hơn trên ảnh thật.
2	Adaptive mask refinement	Giải quyết trade-off giữa IoU/F1 và utility cho LaMa.	Thuật toán confidence-aware, đo độ rộng crack, UI chỉnh mask.	Ảnh sau inpainting ít sọc và ít xóa nhầm hơn.
3	Xây dựng benchmark cho module màu	Thiếu bằng chứng định lượng thuyết phục.	Synthetic test split, real-image review set, LPIPS, user study.	Đánh giá màu khách quan, so sánh được.
4	Thu thập paired data cho color restoration	Domain gap hiện tại lớn, heuristic control chưa tối ưu.	Ảnh thật suy giảm và ảnh sạch tương ứng (khó).	Fine-tune hoặc học lại model màu trên dữ liệu thật.
5	Domain-adapt inpainting backend	Giúp backend hiểu texture giấy cũ và vết nứt tốt hơn.	Dữ liệu, GPU, protocol huấn luyện ổn định.	Tăng chất lượng lấp vùng hỏng khó.
6	Deployment và interactive UI	Tăng khả năng chạy lại, demo và sử dụng thực tế.	Docker/Colab, artifact automation, mask editor.	Hệ thống dễ tái lập và phù hợp workflow bán tự động.

Trong các hướng trên, mở rộng dữ liệu segmentation và tối ưu mask là hai bước nên làm trước. Đối với module màu, cần bắt đầu bằng việc chuẩn hóa benchmark và đánh giá lại toàn diện, từ đó mới xác định được cải thiện nào thực sự có giá trị. Nếu segmenter chưa được huấn luyện trên dữ liệu thật đủ đa dạng hoặc mask chưa phù hợp với LaMa, việc thay backend inpainting lớn hơn hoặc cải tiến module màu có thể không giải quyết đúng nguyên nhân lỗi. Ngược lại, khi dữ liệu và mask đã được củng cố, fine-tune LaMa, nâng cấp color restoration hoặc thử diffusion-based inpainting sẽ có nền

tăng đánh giá rõ hơn.

6.13. Kết luận chương

Chương 6 đã phân tích các hạn chế của hệ thống theo từng nhóm nguyên nhân: dữ liệu, mô hình phân đoạn, mask refinement, inpainting backend, **phục hồi màu**, đánh giá, triển khai và phạm vi bài toán. Hệ thống đã chứng minh tính khả thi của pipeline mô-đun segmentation-inpainting-color restoration trong phạm vi crack/scratch restoration. Tuy nhiên, chất lượng cuối vẫn bị chi phối mạnh bởi dữ liệu thật có nhãn, domain gap, hình thái mask, giới hạn của pretrained inpainting backend, và **tính heuristic của module phục hồi màu**.

R014 cho thấy encoder mạnh hơn cải thiện segmentation, nhưng restoration phụ thuộc vào mask refinement. LaMa giúp hệ thống chạy được trong điều kiện tài nguyên hạn chế, nhưng chưa phải backend được domain-adapt. CodeFormer có thể cải thiện cảm nhận vùng mặt nhưng cần được giữ như tùy chọn do rủi ro hallucination. **Module phục hồi màu đạt các kết quả ước tính tốt nhưng vẫn thiếu benchmark chính thức, dựa nhiều vào synthetic data, và các cơ chế control còn heuristic.**

Hướng phát triển quan trọng nhất là xây dựng dữ liệu ảnh thật có nhãn quy mô lớn hơn, cải thiện adaptive mask refinement, **xây dựng benchmark cho module màu**, mở rộng protocol đánh giá restoration và đóng gói môi trường chạy tái lập hơn. Những hướng này không chỉ tăng chất lượng kỹ thuật của hệ thống, mà còn giúp các kết luận trong tương lai có nền tảng thực nghiệm vững hơn.=====

Chương 7

TỔNG KẾT VÀ KẾT LUẬN

7.1. Mở đầu

Các chương trước đã trình bày toàn bộ quá trình xây dựng hệ thống phục hồi ảnh cũ: từ phân tích bài toán, cơ sở lý thuyết, quá trình phát triển phương pháp, thiết kế hệ thống, thiết lập thực nghiệm, kết quả đánh giá đến các hạn chế và hướng phát triển. Chương 8 có vai trò tổng kết các kết quả chính và trả lời lại các mục tiêu đã đặt ra ở đầu báo cáo.

Trọng tâm của chương này không phải bổ sung thêm thí nghiệm mới, mà kết nối các bằng chứng đã có thành một kết luận thống nhất. Đề tài không được diễn giải như một hệ thống phục hồi hoàn hảo mọi ảnh cũ. Giá trị chính của đề án nằm ở việc xây dựng được một pipeline mô-đun có khả năng chạy, có thể phân tích lỗi theo từng bước, và cho thấy rõ vai trò của dữ liệu, mặt nạ và chiến lược hậu xử lý đối với chất lượng phục hồi cuối cùng.

7.2. Tổng kết bài toán và hướng tiếp cận

Bài toán được nghiên cứu là phục hồi ảnh cũ, với trọng tâm triển khai là phát hiện và lấp các vết nứt hoặc vết xước trên ảnh đã số hóa, đồng thời có bước phục hồi màu sau inpainting. Ảnh cũ thường chứa suy thoái hỗn hợp: một số lỗi lan rộng trên toàn ảnh như nhiễu, mờ, phai màu; một số lỗi có cấu trúc rõ như crack, scratch. Trong phạm vi đề án, nhóm tập trung vào nhóm suy thoái có cấu trúc trước, sau đó xử lý suy giảm màu còn tồn tại.

Hướng tiếp cận ban đầu là U-Net end-to-end, tạo baseline nhưng qua thực nghiệm cho thấy chưa phù hợp với ảnh cũ thật (output mờ, bệt). Điều này dẫn đến quyết định chuyển sang pipeline mô-đun gồm: phân đoạn crack/scratch, tinh chỉnh mask, inpainting bằng LaMa, **phục hồi màu bằng mô hình Lab residual + inference control + CCM**, và tùy chọn CodeFormer cho khuôn mặt. Cách tổ chức này cho phép quan sát output trung gian, thay thế từng module độc lập và phân tích lỗi rõ hơn.

7.3. Tổng kết quá trình phát triển phương pháp

7.3.1. Giai đoạn end-to-end và chuyển hướng

Quá trình phát triển mang tính lặp, bắt đầu từ baseline U-Net end-to-end, thử các biến thể loss (L1, SSIM, masked loss). Các thử nghiệm này cho thấy giới hạn của việc tối ưu pixel toàn ảnh khi bài toán chứa suy thoái có cấu trúc. Sau đó, nhóm chuyển sang segmentation, xây dựng dữ liệu synthetic theo hướng data-centric (Crack Bank, heightmap, Phong illumination, alpha blending). R009 phát hiện domain gap rất lớn (Val IoU 0.4171 synthetic $\rightarrow$ Real Test IoU 0.0022), buộc nhóm chuyển sang real-domain fine-tuning và chuẩn hóa dữ liệu ảnh thật.

7.3.2. Phát triển segmentation và bài học mask morphology

Chuỗi R006–R013 cho thấy tiến trình ra quyết định dựa trên quan sát thực nghiệm: khi augmentation không đủ $\rightarrow$ đổi loss; khi synthetic không tổng quát $\rightarrow$ fine-tune real-domain; khi thin mask chưa phù hợp với inpainting $\rightarrow$ chuyển sang repair-oriented mask; khi manual data quá nhỏ gây overfit $\rightarrow$ không chọn R012. R013 đóng vai trò segmenter ổn định, R014 được phát triển với ResNet-34 encoder để kiểm tra tác động của backbone mạnh hơn.

Kết quả R014 tiếp tục làm rõ bài học quan trọng: segmentation tốt hơn theo IoU/F1 chưa chắc trực tiếp tạo ảnh phục hồi tốt hơn. Mask thô của R014 bám sát vết nứt, nhưng LaMa cần vùng bao lề đủ rộng. Vì vậy, threshold/dilation sweep trở thành bước cần thiết để biến mask segmentation thành mask phù hợp cho inpainting.

7.3.3. Phát triển module phục hồi màu

Module phục hồi màu được xây dựng độc lập với chiến lược: dữ liệu paired synthetic (profile faded_color_v2), OpenCV conservative preprocessing, U-Net dự đoán Lab residual (giới hạn L15, ab40), loss kết hợp RGB L1, L L1, ab L1, SSIM, histogram EMD, identity loss (trọng số 0.2). Sau huấn luyện, inference được kiểm soát bằng Lab protected blending ($sL=0.35$, $sab=0.65$), chroma gate (giảm strength khi mean chroma thấp), và diagonal CCM (gain $\pm 15\%$, strength 45%). Module cho kết quả ước tính PSNR 24.126 dB, SSIM 0.8724, DeltaE 6.7315, vượt trội so với hiệu chỉnh toàn cục, nhờ khả năng điều chỉnh màu theo vùng (da, nền, quần áo khác nhau). Tuy nhiên, vẫn còn các hạn chế như domain gap synthetic-real, thiếu benchmark chính thức, và các tham số control mang tính heuristic.

7.4. Tổng kết kết quả thực nghiệm chính

Các kết quả thực nghiệm chính được tóm tắt theo bốn nhóm: end-to-end baseline, segmentation, restoration + mask morphology, và phục hồi màu.

Bảng 7.1: Các kết quả thực nghiệm chính được tổng kết (bao gồm color restoration)

Nhóm kết quả	Số liệu chính	Ý nghĩa trong đề tài
Baseline end-to-end	Model A: PSNR 23.3540, SSIM 0.7662 trên synthetic	Baseline hữu ích nhưng không đủ ổn định cho ảnh cũ thật.
Domain gap	R009: Synthetic Val IoU 0.4171, Real Test IoU 0.0022	Synthetic pretraining đơn thuần không đủ để triển khai trên ảnh thật.
R013 final	Test IoU 0.366412, Test F1 0.536312	Segmenter ổn định, đóng vai trò fallback/default.
R014 final	Test IoU 0.450604, Test F1 0.621264	ResNet-34 encoder cải thiện segmentation trên cùng split.
Delta R014 – R013	Test IoU +0.084192, Test F1 +0.084952	Cải thiện rõ về mask benchmark, nhưng chưa đủ để kết luận restoration luôn tốt hơn.
Restoration check (15 mẫu)	R013: PSNR 16.69/MAE 30.31; R014 no-dilation: 16.59/30.56	Mask morphology ảnh hưởng trực tiếp đến ảnh inpainting cuối.
Threshold/dilation cho R014	policy 0.30 + dilation 3x3; masked MAE cải thiện -1.04	Policy demo hợp lý cho R014 trong phạm vi kiểm tra 15 mẫu.
Phục hồi màu (ước tính)	PSNR 24.126 dB, SSIM 0.8724, DeltaE 6.73, LPIPS chưa đo	Mô hình Lab residual + inference control đạt chất lượng tốt hơn hiệu chỉnh toàn cục, có khả năng điều chỉnh theo vùng.
Smoke test	Demo3: Mask IoU 0.99977; PSNR 66.6367 dB	Kiểm tra luồng code/golden output, không phải benchmark chất lượng AI.

7.5. Mức độ hoàn thành mục tiêu đề tài

Các mục tiêu đặt ra ở Chương 1 được hoàn thành ở các mức độ khác nhau. Phần trọng tâm (baseline, dữ liệu crack/scratch, segmenter, mask refinement, LaMa integration, ****color restoration module****, CLI/UI, phân tích kết quả) đã được thực hiện. Một số hướng mở rộng (fine-tune LaMa, phục hồi đa tác vụ, colorization chính thức, super-resolution) được giữ ở mức định hướng tương lai.

Bảng 7.2: Đối chiếu mục tiêu đề tài và mức độ hoàn thành (có bổ sung color restoration)

Mục tiêu	Cách thực hiện trong đồ án	Bảng chứng/kết quả	Mức độ
Xây dựng baseline end-to-end	Huấn luyện U-Net image-to-image với các biến thể loss	Model A và các biến thể, kết quả synthetic và quan sát blur	Hoàn thành
Thiết kế dữ liệu crack/scratch	Data-centric pipeline (Crack Bank, normal map, Phong, alpha blending); real-domain set	Pipeline data-centric và tập r013_finetune_set 118 valid pairs	Hoàn thành
Huấn luyện segmenter	Chuỗi R006–R013 và mở rộng R014 ResNet-34 encoder	R013/R014 final metrics trên cùng split	Hoàn thành
Tích hợp mask refinement	Kết hợp DL mask, CV cues, morphology; thử threshold/dilation	Policy R014 threshold 0.30 + dilation 3x3	Hoàn thành
Tích hợp LaMa backend	Gọi LaMa pretrained/local backend qua wrapper/subprocess	Pipeline image + refined mask → restored output	Hoàn thành ở mức tích hợp pretrained
Xây dựng module phục hồi màu	**ColorRestorationUNet (Lab residual), synthetic training, inference control, CCM**	**PSNR 24.126 dB, SSIM 0.8724, DeltaE 6.73 (ước tính)**	**Hoàn thành (chờ benchmark chuẩn)**
Bổ sung CLI/UI/readiness checker	Đóng gói pipeline để chạy demo và kiểm tra artifact/dependency	CLI, Gradio UI, readiness checker, regression test	Hoàn thành
Phân tích kết quả trung thực	Tách segmentation benchmark, restoration check, qualitative demo, smoke test, color evaluation	Chương 5, 6, 7 phân tích phạm vi đọc kết quả	Hoàn thành
Fine-tune inpainting và restoration đa tác vụ	Chưa thực hiện do thiếu dữ liệu sạch và tài nguyên GPU	Đưa vào hướng phát triển	Chưa triển khai

7.6. Đóng góp và bài học rút ra

7.6.1. Đóng góp chính

1. **Chuyển hướng thành công từ end-to-end sang pipeline mô-đun inpainting-color restoration.** Thiết kế này phù hợp với bản chất vết nứt/vết xước (cần định vị trước khi lấp) và suy giảm màu (có thể xử lý sau inpainting), đồng thời giúp chẩn đoán lỗi tốt hơn.
2. **Quy trình data-centric cho crack/scratch segmentation.** Nhóm đầu tư vào cách tạo dữ liệu, chuẩn hóa mask, phân tích domain gap, chuyển sang real-domain fine-tuning. Bài học: với ảnh cũ, dữ liệu và target mask có vai trò ngang với kiến trúc.
3. **So sánh hai cấu hình segmenter trong cùng điều kiện.** R013 (custom lightweight Attention U-Net) ổn định, nhẹ, phù hợp fallback. R014 (ResNet-34 encoder) cải thiện rõ segmentation benchmark. Tuy nhiên, restoration lại nhấn mạnh rằng mask cho inpainting cần hình thái phù hợp, không chỉ đúng pixel crack.
4. **Xây dựng module phục hồi màu dựa trên Lab residual với khả năng điều chỉnh theo vùng.** Mô hình vượt trội so với hiệu chỉnh toàn cục, cho thấy việc tách luminance và chroma, kết hợp inference control heuristic, có thể mang lại kết quả khả quan ngay cả khi chỉ huấn luyện trên dữ liệu synthetic.

7.6.2. Bài học phương pháp luận

- Không nên đánh đồng metric ở các tầng khác nhau: IoU/F1 đánh giá segmentation mask; PSNR/MAE trong restoration check đánh giá ảnh sau inpainting có reference; PSNR/SSIM/DeltaE cho color restoration; Demo3 regression test đánh giá sự ổn định của code. Mỗi chỉ số có vai trò riêng, kết luận chỉ có giá trị khi đặt đúng bối cảnh.
- Domain gap giữa synthetic và real là rào cản lớn, cần được phát hiện sớm và xử lý bằng real-data fine-tuning, không chỉ bằng cải thiện loss hay augmentation.
- Mask morphology quan trọng không kém segmentation accuracy; mask tối ưu cho benchmark chưa chắc tối ưu cho downstream task (inpainting).
- Đối với phục hồi màu, huấn luyện trên synthetic có thể đạt kết quả tốt trên tập ước tính, nhưng cần cơ chế control (blending, chroma gate, CCM bảo thủ) để an toàn khi triển khai thực tế. Benchmark chuẩn trên test split độc lập là yêu cầu bắt buộc trước khi khẳng định chất lượng.

7.7. Giới hạn còn lại và kết luận cuối cùng

Dù đạt được các mục tiêu chính, hệ thống vẫn có nhiều giới hạn: tập ảnh thật có nhãn segmentation còn nhỏ (118 cặp, test split 17), restoration check mới ở quy mô 15 mẫu, LaMa dùng pretrained chưa fine-tune cho miền ảnh cũ, CodeFormer chưa có metric bảo toàn danh tính. Riêng module phục hồi

màu: thiếu benchmark chính thức trên test split theo source ID, chỉ mới ước tính; inference control ($s_L=0.35$, $sab=0.65$, chroma gate) mang tính heuristic, chưa tối ưu; chưa đo LPIPS; CCM diagonal chưa xử lý được cross-channel cast; vẫn còn domain gap giữa synthetic và ảnh thật. Các hướng như LPIPS/FID, no-reference IQA, user study, colorization thực sự, denoising, deblurring, super-resolution chưa được triển khai như kết quả chính.

Do đó, kết luận hợp lý là: **đồ án đã xây dựng được một hệ thống phục hồi ảnh cũ khá hoàn chỉnh, tập trung vào crack/scratch restoration và phục hồi màu sau inpainting, có kiến trúc mô-đun, có các mô hình phân đoạn được huấn luyện và so sánh (R013/R014), có mask refinement, có LaMa inpainting backend, có module phục hồi màu dựa trên Lab residual với cơ chế control an toàn, có UI/CLI và quy trình kiểm thử phần mềm. Hệ thống có khả năng tạo kết quả hợp lý về mặt thị giác trong phạm vi các vết hư hỏng nhỏ đến trung bình và suy giảm màu nhẹ đến trung bình, nhưng chưa phải hệ thống phục hồi ảnh cũ hoàn chỉnh cho mọi dạng suy thoái.**

Giá trị chính của đề tài nằm ở quá trình nghiên cứu có phân tích: bắt đầu từ baseline, nhận diện domain gap, thay đổi chiến lược dữ liệu, xây dựng pipeline mô-đun, so sánh R013/R014 và phát hiện vai trò then chốt của mask morphology, đồng thời thiết kế thành công module phục hồi màu có khả năng điều chỉnh theo vùng. Những kết quả này tạo nền tảng rõ ràng cho các hướng phát triển tiếp theo, đặc biệt là mở rộng dữ liệu thật có nhãn (cả segmentation và color), tinh chỉnh mask thích ứng, xây dựng benchmark restoration quy mô hơn, domain-adapt backend inpainting và hoàn thiện module màu (benchmark, LPIPS, CCM 3x3, adaptive control).

Tổng kết lại, đề tài hoàn thành mục tiêu của một đồ án Deep Learning theo hướng vừa có mô hình học sâu, vừa có pipeline vận hành, vừa có phân tích thực nghiệm và giới hạn diễn giải rõ ràng. Hệ thống không chỉ là một bản demo before-after, mà là một quá trình thiết kế và kiểm chứng có cấu trúc cho bài toán phục hồi vết nứt, vết xước và suy giảm màu trên ảnh cũ.

Tài liệu tham khảo

- [1] Z. Wan, B. Zhang, D. Chen, P. Zhang, D. Chen, J. Liao, and F. Wen, “Bringing Old Photos Back to Life,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.
- [2] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, 2015.
- [3] O. Oktay, J. Schlemper, L. Le Folgoc, M. Lee, M. Heinrich, K. Misawa, K. Mori, S. McDonagh, N. Y. Hammerla, B. Kainz, B. Glocker, and D. Rueckert, “Attention U-Net: Learning Where to Look for the Pancreas,” *arXiv preprint arXiv:1804.03999*, 2018.
- [4] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [5] R. Suvorov, E. Logacheva, A. Mashikhin, A. Remizova, A. Ashukha, A. Silvestrov, N. Kong, H. Goka, K. Park, and V. Lempitsky, “Resolution-robust Large Mask Inpainting with Fourier Convolutions,” in *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2022.
- [6] S. Zhou, K. C. K. Chan, C. Li, and C. C. Loy, “Towards Robust Blind Face Restoration with Codebook Lookup Transformer,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [7] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, “Image Quality Assessment: From Error Visibility to Structural Similarity,” *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600–612, 2004.
- [8] S. S. M. Salehi, D. Erdogmus, and A. Gholipour, “Tversky Loss Function for Image Segmentation Using 3D Fully Convolutional Deep Networks,” in *Machine Learning in Medical Imaging (MLMI)*, 2017.

Chương A

Khung phân công công việc nhóm

Bảng A.1: Phân công công việc (khung)

STT	Họ tên	MSSV	Vai trò chính	Nhiệm vụ đã thực hiện	Mức độ đóng góp
1	[Họ tên]	[MSSV]	[Ví dụ: dữ liệu]	[Mô tả]	[%]
2	[Họ tên]	[MSSV]	[Ví dụ: mô hình]	[Mô tả]	[%]
3	[Họ tên]	[MSSV]	[Ví dụ: UI/demo]	[Mô tả]	[%]
4	[Họ tên]	[MSSV]	[Ví dụ: báo cáo]	[Mô tả]	[%]